

Санкт-Петербургский политехнический университет Петра Великого
Физико-Механический Институт
ВШПМиВФ

Разработка модели глубокого обучения для прогнозирования продуктивности сельскохозяйственных растений по генетическим маркерам

Выпускная квалификационная работа

Выполнил студент группы 5040102/40201: Чибышев Т.А.
Руководитель: к. б. н., доцент Козлов К.Н.

08.06.26

Базовые понятия генетики

Что такое ген?

Участок ДНК, кодирующий белок или РНК.
Определяет наследственные признаки.

У растений тысячи генов, расположенных
на хромосомах.


Эпистаз - это взаимодействие генов, когда один
ген влияет на проявление другого.

Селекция - это отбор лучших растений для
размножения.

Что такое SNP (ОНП — однонуклеотидный полиморфизм)?

SNP (снип) — отличие в ДНК в одной позиции (А, Т, G или С). Применяется в
качестве генетических маркеров

Пример: у одного растения С, у другого Т.



Актуальность и проблема

- ▶ **Вызов:** Традиционная селекция медленная, статистические методы (GBLUP, rrBLUP) плохо ловят нелинейные и эпистатические взаимодействия генов.
- ▶ **Идея:** Трансформеры (механизм внимания) эффективны для сложных зависимостей.
- ▶ **Проблема:** Не хватает интерпретируемых моделей для разных культур.



Обзор существующих решений

- ▶ **Классические статистические методы:**
 - ▶ rrBLUP, GBLUP, байесовские подходы (BGLR)
- ▶ **Преимущество:** эффективны при $m \gg n$ (SNP больше образцов)
- ▶ **Ограничение:** не улавливают нелинейные и эпистатические взаимодействия
- ▶ **Методы глубокого обучения (CNN):**
 - ▶ Свёрточные сети для выявления локальных паттернов
- ▶ **Пример:** прогнозирование признаков нута [Bankin et al., 2024]
- ▶ **Ограничение:** не всегда учитывают глобальные взаимосвязи
- ▶ **Трансформерные архитектуры:**
 - ▶ Механизм многоголового внимания для моделирования любых взаимодействий [Vaswani et al., 2017]
- ▶ **Примеры:** предсказание устойчивости ячменя к фузариозу [Jubair et al., 2021]
- ▶ **Ограничение:** требуют адаптации к SNP-данным (агрегация по генам)
- ▶ **Предшественник (Реутов, 2025):**
 - ▶ Трансформерная модель для нута (TSW, Pht, Blvd)
- ▶ **Что сделано:** свёрточная агрегация SNP по генам, аугментация MixUp
- ▶ **Что не решено:** нет учёта важности отдельных SNP внутри гена, нет регуляризации скрытых представлений
- ▶ **→ Пробелы, которые закрывает моя работа:**
 - ▶ Механизм внимания на уровне SNP (адаптивное взвешивание)
 - ▶ Реконструкционная регуляризация (стабилизация обучения)
 - ▶ Тестирование на трёх культурах с разной плотностью SNP
 - ▶ Интерпретация через значения Шепли

Цели и задачи

- ▶ **Цель:** разработать и программно реализовать модель глубокого обучения для прогнозирования фенотипов по SNP с высокой точностью и возможностью интерпретации.
- ▶ **Задачи:**
 - ▶ Провести анализ существующих методов.
 - ▶ Разработать архитектуру модели.
 - ▶ Реализовать программный комплекс.
 - ▶ Провести эксперименты.
 - ▶ Выполнить интерпретацию через значения Шепли.

Описание данных

Генетические данные				
Культура	Образцов	SNP	Генов	SNP/ген
Нут	553	5.8K	2.8K	2.0
Рис	469	1.7K	1.6K	1.1
Рапс	991	1.27M	60.8K	21.3

1. SNP-данные (генотипы)
 2. Фенотипы
 3. Аннотация (SNP → ген)
- Необходима для:
- группировки SNP по генам
 - интерпретации результатов

Фенотипические признаки			
Культура	Признак	Обозначение	Кол-во образцов
Нут	Масса тысячи семян	TSW	553
	Высота растения	Pht	553
Рис	Высота растения	Plant height	469
	Число побегов	Tiller number	469
Рапс	Время цветения	FloweringTime	926
	Содержание масла	OilContent	279

Ссылки на источники данных:

- Нут — данные ВИР (Соколькова и др., 2020)
- Рис — Lu et al., 2015 (BMC Genomics)
- Рапс — CropGS-Hub (Chen et al., 2024; Wu et al., 2019)

Этапы исследования

► **Этап 1. Анализ и оптимизация:**

- Взята базовая модель предшественника (Реутов) для нута.
- Проведена оптимизация гиперпараметров (функция потерь Huber, аугментация MixUp, планировщик).

► **Этап 2. Расширение:**

- Протестирована базовая модель на новой культуре (рис).
- Выявлены ограничения при низкой плотности SNP на ген.

► **Этап 3. Разработка модификаций:**

- Добавлен механизм внимания на уровне SNP (внутри гена).
- Добавлен реконструкционный блок (автокодировщик) для регуляризации.

► **Итог:** Модель протестирована на 3 культурах (нут, рис, рапс).

Постановка задачи

- ▶ **Генотип** i -го образца — вектор SNP-маркеров:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im})^T, x_{ij} \in \{0, 1, 2\},$$

где

- ▶ 0 = более частый вариант (оба аллеля частые)
 - ▶ 1 = смешанный вариант (один частый, один редкий)
 - ▶ 2 = более редкий вариант (оба аллеля редкие)
 - ▶ m - количество снипов
- ▶ **Фенотип** i -го образца — вектор целевых признаков:
$$\mathbf{y}_i = (y_{i1}, y_{i2}, \dots, y_{ik})^T \in \mathbb{R}^k,$$

где k – количество прогнозируемых признаков

- ▶ **Задача:** Построить модель

$f_\theta: \mathcal{X} \rightarrow \mathbb{R}^k$, минимизирующую ошибку:

$$\mathcal{L}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(\mathbf{x}_i), \mathbf{y}_i) \rightarrow \min_\theta$$

ℓ — функция потерь

- ▶ В данной работе ℓ = HuberLoss.
- ▶ Формула:

$$L_\delta(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| < \delta \\ \delta \cdot |y - \hat{y}| - \frac{1}{2}\delta^2, & \text{иначе} \end{cases}$$

где δ — пороговый параметр (в моей работе $\delta = 1.0$)

Модификации

- ▶ **Проблема:** свёртка усредняет SNP внутри гена — все SNP одинаково важны.
- ▶ **Решение:** механизм внимания — модель сама учит веса SNP.
- ▶ **Проблема:** трансформер может терять информацию о генах.
- ▶ **Решение:** дополнительная задача — восстановить исходные SNP по эмбедингам генов.

Гипотеза: процесс обучения стабилизируется, качество прогнозирования улучшится за счет продвинутого механизма агрегации значений ОНП

Архитектура модели

Блок	Что делает	Выход
1. Генетическое кодирование	Агрегация SNP → эмбединги генов	Матрица [N_генов × d]
2. Трансформер	Моделирует взаимодействия между генами	Матрица [N_генов × d]
3. Прогнозирование	CLS-токен + внимание → регрессия	Вектор фенотипов [k]
4. Реконструкция (только обучение)	Восстановление исходных SNP	Вектор SNP [M]


Функция потерь (обучение):

$$L = L_{pred} + \lambda \cdot L_{recon}$$

- L_{pred} — ошибка предсказания фенотипов (HuberLoss)
- L_{recon} — ошибка восстановления SNP (MSE)
- λ — коэффициент регуляризации (убывает со временем)

На этапе
предсказания:
реконструкция
отключается ($\lambda = 0$)

Диаграмма компонентов спроектированной модели



Блок генетического кодирования

▶ Исходные данные:

Вектор SNP: $x_i = (x_{i1}, x_{i2}, \dots, x_{im})^T$, $x_{ij} \in \{0, 1, 2\}$

▶ Шаг 1. Частотное кодирование (нормализация):

$$x'_{ij} = \frac{n_j(x_{ij})}{N_{train}}, \text{ где } n_j(x_{ij}) \text{ — количество}$$

образцов в обучающей выборке со значением x_{ij} для SNP j , N_{train} — размер обучающей выборки.

▶ Шаг 2. Группировка SNP по генам:

- ▶ Используется таблица аннотации SNP → Gene.
- ▶ Пример: ген X содержит SNP1=0.9, SNP2=0.45, SNP3=0.6 → вектор [0.9, 0.45, 0.6].

▶ Шаг 3. Преобразование в эмбединги:

- ▶ Каждый ген получает вектор размерности d .
- ▶ SNP внутри гена агрегируются (механизмом внимания или свёрткой).

▶ 3.1 Проекция каждого SNP в вектор

- ▶ $h_s = x_s \cdot w_{snp}$, $w_{snp} \in \mathbb{R}^d$, где x_s — значение SNP (число), w_{snp} — обучаемый вектор (общий для всех SNP)

▶ 3.2 Вычисление важности каждого SNP

- ▶ $e_s = a^T h_s$, $a \in \mathbb{R}^d$, где a — обучаемый вектор внимания, e_s — сырая оценка важности

▶ 3.3 Нормировка (softmax)

- ▶ $\alpha_s = \frac{\exp(e_s)}{\sum_{k \in \text{gen}} \exp(e_k)}$, где α_s — итоговый вес SNP (сумма весов по гену = 1)

▶ 3.4 Взвешенная сумма

- ▶ $v_{\text{ген}} = \sum_{s \in \text{ген}} \alpha_s \cdot h_s$
- ▶ $v_{\text{ген}}$ — эмбединг гена (вектор длины d)

- ▶ **Результат:** $X \in \mathbb{R}^{N_{\text{samples}} \times N_{\text{genes}} \times d}$

Пример

▶ Исходные данные (гипотетический ген)

Растение	Участок ДНК	Комментарий
Растение 1	AAGCCTA	Исходная последовательность
Растение 2	AAGCTTA	Отличается в позиции 5: C → T

Растение	Генотип	Код ОНП	Частотное кодирование
Растение 1	CC	0	0.90
Растение 2	TT	2	0.02

Идея: Заменить код на частоту встречаемости этого генотипа в обучающей выборке.

Ген	ОНП №1	ОНП №2	ОНП №3
Gen_1	0.90	0.45	0.60

Вектор ОНП для этого гена: $[0.90, 0.45, 0.60]$. Этот вектор подаётся на вход механизму агрегации.

Механизм агрегации:

- ▶ **Вход:** $[0.9, 0.45, 0.6]$ — три SNP
- ▶ **После проекции:** ($w_{snp} = [0.2, 0.5, 0.1]$, размерность $d = 3$)
 - ▶ $h_1 = [0.18, 0.45, 0.09]$,
 - ▶ $h_2 = [0.09, 0.23, 0.05]$,
 - ▶ $h_3 = [0.12, 0.30, 0.06]$
- ▶ **После внимания (веса α получены из a):**
 - ▶ $\alpha_1 = 0.42, \alpha_2 = 0.26, \alpha_3 = 0.32$
- ▶ **Эмбединг гена (взвешенная сумма):**
 - ▶ $v_{ген} = 0.42 \cdot h_1 + 0.26 \cdot h_2 + 0.32 \cdot h_3 = [0.14, 0.34, 0.07]$

Описание других блоков??

- ▶ Трансформерный блок (TransformerBlock) — состоит из нескольких слоёв трансформерного энкодера с механизмом многоголового самовнимания и функцией активации GELU в feed-forward слое.
- ▶ Блок прогнозирования (PredictionBlock) — преобразует выход трансформера в предсказания фенотипов через два полносвязных слоя с активацией ReLU.
- ▶ Реконструкционный блок (reconstruction_head) — вспомогательный автокодировщик, восстанавливающий исходные SNP-значения по агрегированным генным представлениям.

Результаты оптимизации гиперпараметров

Эксперимент	Ключевое изменение	TSW (r)	Pht (r)	Сжатие дисперсии TSW	Сжатие дисперсии Pht
Базовый	Свёрточная агрегация SNP, MSE	0.907	0.775	31%	40%
Первый эксперимент	+ SmoothL1Loss + MixUp + scheduler	0.910	0.790	31%	40%
Второй эксперимент	+ внимание на уровне SNP + LayerNorm + реконструкция	0.881	0.773	26%	36%

Выводы:

- Оптимизация гиперпараметров повышает корреляцию, но не устраняет нестабильность
- Механизм внимания на уровне SNP стабилизирует обучение и лучше сохраняет дисперсию
- Итоговая архитектура выбирает стабильность и сохранение индивидуальных различий в ущерб максимальной корреляции


Результаты модифицированной модели на нуте и рисе

- Нут:
 - TSW 0.901 (база 0.910),
 - Pht 0.773 (база 0.790) — проигрыш 1–2%
- Рис:
 - высота 0.830 (база 0.847),
 - побеги 0.576 (база 0.600) — проигрыш 2–4%

Модифицированная модель обучается стабильнее и достигает минимального значения функции потерь на 10 процентов меньше по сравнению с базовой моделью.

► Гипотеза

Эффективность модифицированной модели (внимание на уровне SNP + реконструкция) зависит от плотности SNP на ген.



Стратегии отбора генов

- ▶ **1. Взвешенный отбор (weighted selection)**
- ▶ Гены ранжируются по количеству SNP (от большего к меньшему)
- ▶ Разбиваются на 4 квартиля
- ▶ Целевое распределение отбираемых генов:
 - ▶ 1-й квартиль (меньше всего SNP) → вес 0.1
 - ▶ 2-й квартиль → вес 0.2
 - ▶ 3-й квартиль → вес 0.3
 - ▶ 4-й квартиль (больше всего SNP) → вес 0.4
- ▶ **Идея:** гены с большим числом SNP потенциально несут больше информации
- ▶ **2. Равномерный отбор по геному (uniform position selection)**
- ▶ Для каждого гена вычисляется глобальная позиция на геноме (с учётом длины хромосом)
- ▶ Гены сортируются по глобальной позиции
- ▶ Отбираются гены с равномерным шагом по всей длине генома
- ▶ **Идея:** равномерно покрыть весь геном, независимо от плотности генов
- ▶ **3. Равномерный отбор внутри хромосом (uniform per chromosome selection)**
- ▶ Для каждой хромосомы определяется целевое количество генов:
 - ▶ Пропорционально физической длине хромосомы
 - ▶ Минимум — 1 ген на хромосому
- ▶ Внутри каждой хромосомы гены сортируются по позиции
- ▶ Отбираются с равномерным шагом внутри хромосомы
- ▶ **Идея:** равномерное покрытие как по хромосомам, так и внутри них

Сравнение стратегий отбора генов

Стратегия	Принцип	SNP	Корреляция (FT)	Корреляция (GlucO)
Взвешенная (weighted)	Больше SNP → выше шанс попасть в выборку (веса квартилей 0.1/0.2/0.3/0.4)	85 208	0.798	0.773
Равномерная по геному	Равномерный шаг по всей длине генома (все хромосомы склеены)	63 035	0.850	0.776
Равномерная по хромосомам	Пропорционально длине хромосомы + равномерный шаг внутри	63 005	0.850	0.783

Вывод: равномерные стратегии дают +6.5% корреляции при на 26% меньше SNP.

Результаты на rapse

Метод агрегации	FT (r)	GC (r)	Число параметров
Свёртка (Conv1d)	0.854	0.749	6.47M
Внимание (Attention)	0.890	0.772	4.85M
Изменение	+3.6%	+2.3%	-25%

Ошибка	Без аугментации	С аугментацией	Изменение
MAPE	44.5%	35.5%	-9%
MAE	28.19	24.38	-3.81

Гипотеза подтверждена:

- механизм внимания на уровне SNP наиболее эффективен при высокой плотности SNP на ген. Для обоих признаков достигнут прирост корреляции: +3.6% для времени цветения, +2.3% для глюкозинолатов, при этом число параметров сократилось на 25%.
- Аугментация MixUp существенно улучшает абсолютную точность предсказания сложных признаков (MAPE глюкозинолатов ↓ на 9%), что особенно важно при ограниченном количестве обучающих образцов (189).

Выявление взаимодействий генов с помощью значений Шепли

- ▶ **Метод:** анализ парных взаимодействий генов

- ▶ **Идея:**

Посмотреть, насколько совместное добавление генов i и j отличается от суммы их индивидуальных эффектов.

- ▶ **Формула парного взаимодействия:**

$$\varphi_{i,j} = \mathbb{E}_{S \subseteq N \setminus \{i,j\}} \left[\underbrace{f(S \cup \{i,j\})}_{\text{оба}} - \underbrace{f(S \cup \{i\})}_{\text{только } i} - \underbrace{f(S \cup \{j\})}_{\text{только } j} + \underbrace{f(S)}_{\text{ни одного}} \right]$$

- ▶ **Центральность гена g :**


$$C_g = \sum_{h \neq g} |\varphi_{g,h}|$$

Результаты выделения генов для риса

Ген	Центральность	Роль
Os01g0125800	0.421	Участвует в 7 взаимодействиях (4+ / 3-)
Os01g0150000	0.373	Участвует в 2 отрицательных

Биологическая аннотация:


- Os01g0125800 → AIP1 (перестройка цитоскелета)
- Os01g0150000 → OsCER10 (биосинтез воска кутикулы)



Результаты выделения генов для рапса

Ген	Центральность
gene- LOC106381653	0.0264

Вывод: структура взаимодействий различается для разных культур. Выявлены гены-мишени для селекции.




Выводы


- ▶ **1. Разработана модель глубокого обучения**
 - ▶ Модель протестирована на трёх культурах: нут, рис, рапс
- ▶ **2. Механизм внимания на уровне SNP доказал свою эффективность**
 - ▶ Рапс: +3.6% корреляции (0.854 → 0.890) при -25% параметров
 - ▶ Гипотеза подтверждена: внимание эффективно при высокой плотности SNP
- ▶ **3. Реконструкционная регуляризация стабилизировала обучение**
 - ▶ Плавная сходимость функции потерь (без резких колебаний)
 - ▶ Лучшее сохранение дисперсии предсказаний
- ▶ **4. Достигнута высокая точность прогнозирования**
 - ▶ Нут: TSW (масса семян) $r = 0.881$ | Pht (высота) $r = 0.773$
 - ▶ Рис: Plant height $r = 0.830$ | Tiller number $r = 0.516$
 - ▶ Рапс: FloweringTime $r = 0.890$ | GlucosinolateContent $r = 0.772$
- ▶ **5. Аугментация MixUp улучшила точность для сложных признаков**
 - ▶ GlucosinolateContent (рапс): MAPE ↓ на 9% (44.5% → 35.5%) при 189 обучающих образцах
- ▶ **6. Равномерные стратегии отбора генов эффективнее взвешенной**
 - ▶ +6.5% корреляции для времени цветения рапса (0.798 → 0.850)
 - ▶ На 26% меньше SNP (85K → 63K)
- ▶ **7. Интерпретация модели через значения Шепли**
 - ▶ Выявлены гены-«хабы»:
 - ▶ Рис: Os01g0125800 (AIP1, перестройка цитоскелета)
 - ▶ Рапс: gene-LOC106381653 (функция требует валидации)
- ▶ **8. Технические характеристики вычислительной машины**
 - ▶ CPU: AMD Ryzen 7 5800H
 - ▶ GPU: NVIDIA RTX 3050 TI Laptop 4 GB
 - ▶ RAM: 16 GB DDR4
 - ▶ Время обучения (рапс, 3000 генов): ~4–5 часов

Гистограммы распределения фенотипических признаков рапса

Распределение признака: FloweringTime
(n=926 образцов)



Распределение признака: GlucosinolateContent
(n=279 образцов)




HuberLoss (Smooth L1 Loss)

- ▶ **HuberLoss** — это комбинированная функция потерь, которая объединяет преимущества **MSE** (среднеквадратичной ошибки) и **MAE** (средней абсолютной ошибки).

- ▶ **Формула**

- ▶
$$L_{\delta}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| < \delta \\ \delta \cdot |y - \hat{y}| - \frac{1}{2}\delta^2, & \text{иначе} \end{cases}$$


- ▶ где δ — пороговый параметр (в вашей работе $\delta = 1.0$)




Аугментация

- ▶ **Проблема:**
- ▶ В геномном прогнозировании ограниченное количество образцов (например, 469 у риса, 553 у нута)
- ▶ Модель легко переобучается на малой выборке
- ▶ Нужно искусственно увеличить разнообразие обучающих примеров
- ▶ **Используемый метод: MixUp**
- ▶ **Идея:** создавать синтетические образцы как линейную комбинацию двух реальных образцов.
- ▶ **Формула:**
- ▶ Для двух случайных образцов (x_i, y_i) и (x_j, y_j) :
- ▶ $\tilde{x} = \lambda \cdot x_i + (1 - \lambda) \cdot x_j$
- ▶ $\tilde{y} = \lambda \cdot y_i + (1 - \lambda) \cdot y_j$
- ▶ где $\lambda \sim \text{Beta}(\alpha, \alpha)$ — параметр смешивания.
- ▶ **Я использовал:** $\alpha = 0.3$, λ генерируется из $\text{Beta}(0.3, 0.3)$

Динамика функции потерь базовой модели



Динамика функции потерь модифицированной модели на нуте



Дополнительные результаты

Эксперимент	Результат
Аугментация MixUp для глюкозинолатов	MAPE ↓ на 8.93%
Мультизадачное обучение (FT + OilContent)	Корреляция FT = 0.809
Усложнение архитектуры (d=64)	+0.4% корреляции при x2 параметров

Культура	Признак	Базовая модель	Модифицированная модель
Нут	TSW (масса семян)	0.910	0.901
	Pht (высота)	0.790	0.773
Рис	Plant height	0.847	0.830
	Tiller number	0.600	0.576

Сложность модели и оптимизация

- ▶ **Проблема:** трансформеры требуют много памяти и времени.
- ▶ **Решение:** компактная конфигурация

Общее число параметров: ~80 млн

Распределение:

Прогнозирование: 26.2М (32%)

Реконструкция: 54.5М (68%) — отключается на инференсе

Кодирование + трансформер: ~0.2М (0.2%)

Время обучения (рапс, 2000 генов): ~2–3 часа на GPU

Параметр	Значение
Размерность эмбединга (d)	48
Слоёв трансформера (L)	4
Голов внимания (h)	4
Размер FFN (d_ff)	128

Пример:

- ▶ **Вход:** $[0.9, 0.45, 0.6]$ — три SNP
- ▶ **После проекции:**
($w_{snp} = [0.2, 0.5, 0.1]$, размерность $d = 3$)
 - ▶ $h_1 = [0.18, 0.45, 0.09]$,
 - ▶ $h_2 = [0.09, 0.225, 0.045]$,
 - ▶ $h_3 = [0.12, 0.30, 0.06]$
- ▶ **После внимания (веса α получены из a):**
 - ▶ $\alpha_1 = 0.42, \alpha_2 = 0.26, \alpha_3 = 0.32$
- ▶ **Эмбединг гена (взвешенная сумма):**
 - ▶ $v_{ген} = 0.42 \cdot h_1 + 0.26 \cdot h_2 + 0.32 \cdot h_3 = [0.137, 0.344, 0.069]$

Агрегация в эмбединг гена

- ▶ **Вход:** вектор SNP для одного гена (разной длины)
- ▶ **Выход:** эмбединг гена (фиксированной длины d)

Пример:

- ▶ **Вход:** $[0.9, 0.45, 0.6]$ — три SNP
- ▶ **После проекции:**
($w_{snp} = [0.2, 0.5, 0.1]$, размерность $d = 3$)
 - ▶ $h_1 = [0.18, 0.45, 0.09]$,
 - ▶ $h_2 = [0.09, 0.225, 0.045]$,
 - ▶ $h_3 = [0.12, 0.30, 0.06]$
- ▶ **После внимания (веса α получены из a):**
 - ▶ $\alpha_1 = 0.42, \alpha_2 = 0.26, \alpha_3 = 0.32$
- ▶ **Эмбединг гена (взвешенная сумма):**
 - ▶ $v_{ген} = 0.42 \cdot h_1 + 0.26 \cdot h_2 + 0.32 \cdot h_3 = [0.137, 0.344, 0.069]$

Шаг 1. Проекция каждого SNP в вектор

- ▶ $h_s = x_s \cdot w_{snp}, w_{snp} \in \mathbb{R}^d$
- ▶ x_s — значение SNP (число)
- ▶ w_{snp} — обучаемый вектор (общий для всех SNP)

Шаг 2. Вычисление важности каждого SNP

- ▶ $e_s = a^\top h_s, a \in \mathbb{R}^d$
- ▶ a — обучаемый вектор внимания
- ▶ e_s — сырая оценка важности

Шаг 3. Нормировка (softmax)

- ▶ $\alpha_s = \frac{\exp(e_s)}{\sum_{k \in \text{ген}} \exp(e_k)}$
- ▶ α_s — итоговый вес SNP (сумма весов по гену = 1)

Шаг 4. Взвешенная сумма

- ▶ $v_{ген} = \sum_{s \in \text{ген}} \alpha_s \cdot h_s$
- ▶ $v_{ген}$ — эмбединг гена (вектор длины d)