

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Физико-Механический Институт

Работа допущена к защите

Руководитель Образовательной программы

_____ К.Н. Козлов

«_____» _____ 202_ г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАБОТА МАГИСТРА
РАЗРАБОТКА МОДЕЛИ ГЛУБОКОГО ОБУЧЕНИЯ ДЛЯ
ПРОГНОЗИРОВАНИЯ ПРОДУКТИВНОСТИ
СЕЛЬСКОХОЗЯЙСТВЕННЫХ РАСТЕНИЙ ПО ГЕНЕТИЧЕСКИМ
МАРКЕРАМ

по направлению подготовки 01.04.02 Прикладная математика и информатика
Направленность (профиль) 01.04.02_01 Прикладная математика и биоинформатика

Выполнил

студент гр. 5040102/40201

Т.А. Чибышев

Руководитель

доцент,

к. б. н., ВШПМиВФ ФизМех, СПбПУ,

К.Н. Козлов

Консультант

по нормоконтролю

Л.А. Арефьева

Санкт-Петербург

2026

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Физико-Механический Институт

УТВЕРЖДАЮ

Руководитель Образовательной программы

_____ К.Н. Козлов

« _____ » _____ 202_г.

ЗАДАНИЕ

на выполнение выпускной квалификационной работы

студенту Чибышеву Тимофею Андреевичу, гр. 5040102/40201

1. Тема работы: «Разработка модели глубокого обучения для прогнозирования продуктивности сельскохозяйственных растений по генетическим маркерам».
2. Срок сдачи студентом законченной работы: 27.05.2026.
3. Обзор литературы по теме ВКР:
 - Juan, W.; Ahn, K. W.; Chen, Y.-G.; Lin, C.-W. DropDAE: Denoising Autoencoder with Contrastive Learning for Addressing Dropout Events in scRNA-seq Data. *Bioengineering* 2025, 12, 829. <https://doi.org/10.3390/bioengineering12080829>
 - Lu Q, Zhang M, Niu X, Wang S, Xu Q, Feng Y, Wang C, Deng H, Yuan X, Yu H, Wang Y, Wei X. Genetic variation and association mapping for 12 agronomic traits in indica rice. *BMC Genomics*. 2015 Dec 16;16:1067. doi: 10.1186/s12864-015-2245-2. PMID: 26673149; PMCID: PMC4681178.
 - Jiaxin Chen, Cong Tan, Min Zhu, Chenyang Zhang, Zhihan Wang, Xuemei Ni, Yanlin Liu, Tong Wei, Xiaofeng Wei, Xiaodong Fang, Yang Xu, Xuehui Huang, Jie Qiu, Huan Liu, CropGS-Hub: a comprehensive database of genotype and phenotype resources for genomic prediction in major crops, *Nucleic Acids Research*, Volume 52, Issue D1, 5 January 2024, Pages D1519–D1529, <https://doi.org/10.1093/nar/gkad1062>
4. Исходные данные по работе:

Данные генетических маркеров и фенотипических характеристик сельскохозяйственных растений, полученные из открытых научных источников и специализированных баз данных..

5. Инструментальные средства:

- языки программирования: Python
- среда разработки: Visual Studio Code
- система контроля версий: git

6. Содержание работы:

- 6.1. Введение. Обоснование актуальности проблемы.
- 6.2. Постановка задачи.
- 6.3. Архитектура модели.
- 6.4. Конфигурации модели и их применение. Вычислительные эксперименты.
- 6.5. Результаты исследований.
- 6.6. Выводы.
- 6.7. Заключение.

7. Перечень графического материала:

- 7.1. Схема работы метода/алгоритма.
- 7.2. Архитектура разработанной программы/библиотеки.

8. Консультанты по работе:

- 8.1. Л.А. Арефьева (нормоконтроль).

9. Дата выдачи задания: 02.10.2025.

Руководитель ВКР _____ К.Н. Козлов

Консультант _____

Задание принял к исполнению 27.05.2026

Студент _____ Т.А. Чибышев

РЕФЕРАТ

На 68 с., 17 рис., 20 табл., 0 прил.

Ключевые слова: нейронные сети, глубокое обучение, трансформеры, геномное прогнозирование, онп, гены, фенотип, аугментация, рис, рапс

Тема выпускной квалификационной работы: «Разработка модели глубокого обучения для прогнозирования продуктивности сельскохозяйственных растений по генетическим маркерам».

В работе разработана архитектура модели глубокого обучения для прогнозирования фенотипических признаков сельскохозяйственных культур на основе SNP-данных. Исследование проведено на трёх культурах: нут, рис и рапс. Рассматривались масса тысячи семян, высота растения, время цветения, содержание масла и глюкозинолатов.

Предложенная модель включает четыре блока: генетического кодирования с механизмом внимания на уровне SNP, трансформерный для моделирования межгенных взаимодействий, прогнозирования фенотипов и реконструкционный для регуляризации скрытых представлений. Для обучения применена многозадачная функция потерь с адаптивным взвешиванием признаков.

Проведена серия вычислительных экспериментов: сравнительный анализ методов аугментации данных, исследование стратегий отбора генов и оценка влияния архитектурных модификаций на точность прогнозирования. Для интерпретации модели использованы значения Шепли, позволившие выявить значимые генные взаимодействия.

Наибольшая точность прогнозирования достигнута для времени цветения рапса (коэффициент корреляции 0.809) и массы тысячи семян нута (0.881). Эффективность подхода подтверждена на данных различных культур, что демонстрирует его обобщающую способность. Разработанная модель может быть применена в селекционных программах для идентификации ключевых генетических маркеров, связанных с продуктивностью растений.

ABSTRACT

On 68 pages, 17 figures, 20 tables, 0 appendices

Keywords: neural networks, deep learning, transformers, genomic prediction, snp, genes, phenotype, augmentation, rice, rapeseed

The subject of the graduate qualification work is «Development of a deep learning model for predicting crop productivity based on genetic markers».

A deep learning architecture for predicting phenotypic traits of agricultural crops from SNP data is developed. The study covers three crops: chickpea, rice and rapeseed. Target traits include thousand seed weight, plant height, flowering time, oil content and glucosinolate content.

The model comprises four blocks: genetic encoding with SNP-level attention, transformer for intergenic interactions, phenotype prediction and reconstruction for regularisation. A multi-task loss with adaptive weighting is employed.

Computational experiments include augmentation methods comparison, gene selection strategies and architectural modifications. Shapley values reveal significant gene interactions.

Top accuracy: rapeseed flowering time (0.809) and chickpea thousand seed weight (0.881). The approach generalises across crops and can be applied in breeding programmes.

СОДЕРЖАНИЕ

Введение	8
1 ПОСТАНОВКА ЗАДАЧИ И ОПИСАНИЕ ИСХОДНЫХ ДАННЫХ	11
1.1 Постановка задачи	11
1.1.1 Генотипические данные	11
1.1.2 Фенотипические данные	12
1.1.3 Задача многомерной регрессии	12
1.1.4 Обобщённая архитектура модели	12
1.1.5 Ключевые модификации	13
1.1.6 Анализ существующих решений	13
1.2 Описание данных	16
1.2.1 Данные по нуту	16
1.2.2 Данные по рису	17
1.2.3 Данные по рапсу	20
1.2.4 Сравнительная характеристика наборов данных	24
1.2.5 Выводы по главе 1	25
2 Разработка архитектуры модели и описание используемых методов	25
2.1 Архитектура модели	25
2.1.1 Блок генетического кодирования (GeneticEncodingBlock)	26
2.1.2 Трансформерный блок (TransformerBlock)	29
2.1.3 Блок прогнозирования (PredictionBlock)	30
2.1.4 Реконструкционный блок (ReconstructionHead)	31
2.1.5 Количество параметров модели	32
2.1.6 Аугментация данных	33
2.1.7 Стратегии отбора генов	35
2.1.8 Настройки процесса обучения	37
2.1.9 Механизмы регуляризации	37
3 Экспериментальное исследование предсказательной способности модели	38
3.1 Сравнительный анализ архитектур на данных нута и риса	38
3.1.1 Экспериментальные условия	38
3.1.2 Результаты на данных нута	39
3.1.3 Результаты на данных риса	40
3.1.4 Сравнительный анализ качества прогнозирования	41
3.1.5 Анализ сжатия дисперсии	42
3.1.6 Анализ устойчивости обучения	43

3.1.7 Эксперименты с базовой моделью.....	43
3.1.8 Анализ влияния архитектурных модификаций.....	44
3.2 Эксперименты на данных рапса	45
3.2.1 Характеристика данных	45
3.2.2 Стратегии отбора генов	46
3.2.3 Сравнение стратегий отбора генов.....	47
3.2.4 Сравнение механизмов агрегации SNP	47
3.2.5 Влияние аугментации	48
3.2.6 Мультизадачное обучение	48
3.2.7 Усложнение архитектуры.....	49
3.2.8 Кросс-культурный анализ.....	50
3.2.9 Выводы по экспериментам на рапсе	50
4 Анализ межгенных взаимодействий с использованием значений Шепли.	51
4.1 Теоретические основы метода Шепли.....	51
4.1.1 Значения Шепли в задачах интерпретации моделей	51
4.1.2 Адаптация для анализа парных взаимодействий генов	52
4.1.3 Вычислительная сложность и приближённые методы	52
4.1.4 Отбор наиболее значимых генов	52
4.2 Результаты анализа на данных риса	53
4.2.1 Экспериментальные условия	53
4.2.2 Матрица взаимодействий генов.....	53
4.2.3 Распределение значений Шепли.....	53
4.2.4 Наиболее выраженные взаимодействия.....	53
4.2.5 Анализ центральности генов	55
4.2.6 Биологические функции ключевых генов	57
4.3 Результаты анализа на данных рапса.....	57
4.3.1 Экспериментальные условия	57
4.3.2 Результаты анализа	57
4.3.3 Анализ центральности генов	58
4.3.4 Аннотация ключевого гена рапса	60
4.3.5 Сравнительный анализ.....	60
4.4 Выводы по главе	61
Заключение	63
Список использованных источников.....	66

ВВЕДЕНИЕ

Актуальность исследования

Современное сельское хозяйство сталкивается с комплексом взаимосвязанных вызовов: истощение природных ресурсов, сокращение пригодных для обработки земель и климатическая нестабильность.[9; 14] Особенно остро эти проблемы проявляются в регионах рискованного земледелия, где продуктивность культур напрямую зависит от устойчивости сортов к засухе, полеганию и другим стрессовым факторам. Традиционная селекция, основанная на фенотипическом отборе, требует значительных временных затрат и не всегда позволяет эффективно выявлять генетические детерминанты хозяйственно ценных признаков.[13]

Современные методы геномного прогнозирования открывают возможность существенного ускорения селекционного процесса за счёт анализа однонуклеотидных полиморфизмов (SNP). Статистические подходы (rrBLUP, GBLUP, байесовские методы) обладают ограниченной способностью улавливать нелинейные и эпистатические взаимодействия между генами. Модели глубокого обучения, в частности архитектуры на основе трансформеров, демонстрируют высокую эффективность в задачах выявления сложных зависимостей в геномных данных, однако их применение для прогнозирования продуктивности сельскохозяйственных культур остаётся недостаточно изученным. В связи с этим разработка интерпретируемой модели глубокого обучения, адаптированной к специфике генетических данных и способной работать с различными культурами, является актуальной задачей.

Объект и предмет исследования

Объект исследования — процесс прогнозирования фенотипических признаков сельскохозяйственных растений по генотипическим данным.

Предмет исследования — архитектура и методы обучения нейросетевой модели на основе трансформеров и механизмов внимания для задач геномного прогнозирования.

Цель и задачи исследования

Цель работы — разработать и программно реализовать модель глубокого обучения для прогнозирования продуктивности сельскохозяйственных растений по

SNP-маркерам, обеспечивающую высокую точность предсказания и возможность интерпретации выявленных генных взаимодействий.

Для достижения цели поставлены следующие **задачи**:

- А. Провести анализ существующих методов геномного прогнозирования, выявить их преимущества и ограничения.
- В. Разработать архитектуру модели, включающую механизм внимания на уровне SNP и реконструкционную регуляризацию.
- С. Реализовать программный комплекс для обучения и тестирования модели на данных различных сельскохозяйственных культур.
- Д. Провести вычислительные эксперименты на данных нута, риса и рапса, оценив точность прогнозирования различных фенотипических признаков.
- Е. Исследовать стратегии отбора генов и методы аугментации данных для повышения обобщающей способности модели.
- Ф. Выполнить интерпретацию модели с помощью значений Шепли для выявления значимых межгенных взаимодействий.

Гипотеза исследования

Предполагается, что введение механизма внимания на уровне отдельных SNP-маркеров и реконструкционной регуляризации позволит повысить устойчивость обучения и сохранить индивидуальные различия между образцами, а разработанная архитектура будет демонстрировать сопоставимую эффективность на данных различных культур.

Методологическая база исследования

Работа базируется на методах машинного обучения и глубокого обучения (трансформеры, механизмы внимания, многозадачное обучение), методах обработки геномных данных (частотное кодирование SNP, агрегация по генам, позиционное кодирование), а также на подходах к интерпретации нейросетевых моделей (значения Шепли). Вычислительные эксперименты проводились с использованием библиотек PyTorch, NumPy, Pandas, scikit-learn.

Научная новизна

- А. Предложена архитектура модели глубокого обучения с механизмом внимания на уровне SNP, позволяющая адаптивно взвешивать вклад отдельных маркеров при формировании генных представлений.
- В. Введена реконструкционная регуляризация скрытых представлений генов, способствующая сохранению информации при прохождении через трансформерный блок.
- С. Разработана многозадачная функция потерь с адаптивным взвешиванием фенотипических признаков на основе обучаемых параметров неопределённости.
- Д. Проведено систематическое сравнение стратегий отбора генов (взвешенной, равномерной по геному, равномерной по хромосомам) применительно к трансформерным архитектурам.

Теоретическая и практическая значимость

Теоретическая значимость заключается в развитии методов применения трансформерных архитектур для задач геномного прогнозирования, в частности в обосновании эффективности иерархического внимания ($\text{SNP} \rightarrow \text{ген} \rightarrow \text{геном}$).

Практическая значимость состоит в создании программной реализации модели, которая может быть использована в селекционных программах для идентификации генетических маркеров, связанных с продуктивностью, устойчивостью к засухе и другими хозяйственно ценными признаками. Результаты experiments на трёх культурах подтверждают применимость подхода в регионах рискованного земледелия для ускоренного выведения адаптированных сортов.

1 ПОСТАНОВКА ЗАДАЧИ И ОПИСАНИЕ ИСХОДНЫХ ДАННЫХ

В данной главе формулируется задача прогнозирования фенотипических признаков сельскохозяйственных растений по генотипическим данным, представленным в виде однонуклеотидных полиморфизмов (SNP). Приводится математическая постановка задачи многомерной регрессии, описывается обобщённая архитектура предлагаемой модели, выделяются её ключевые модификации по сравнению с известными аналогами. Кроме того, даётся характеристика трёх наборов генетических и фенотипических данных (нут, рис, рапс), используемых в вычислительных экспериментах. В 1.1 представлена формальная постановка задачи, в 1.2 приведено описание исходных данных.

1.1 Постановка задачи

Пусть имеется выборка из n образцов сельскохозяйственных растений. Каждый образец характеризуется генотипическими и фенотипическими данными.[12]

1.1.1 Генотипические данные

SNP (ОНП) — это единичное изменение нуклеотида в последовательности ДНК, которое встречается в популяции с частотой не менее 1%. SNP-маркеры являются наиболее распространённым типом генетической изменчивости и используются в качестве молекулярных маркеров для ассоциативных исследований и геномного прогнозирования.

Генотип i -го образца представляется вектором SNP-маркеров:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im})^T \in \mathcal{X},$$

где m — общее количество SNP. Каждый SNP кодируется числом минорных аллелей:

$$x_{ij} \in \{0, 1, 2\},$$

где 0 соответствует мажорной гомозиготе (AA), 1 — гетерозиготе (Aa), 2 — минорной гомозиготе (aa). Таким образом, значение x_{ij} отражает дозу минорного аллеля в генотипе.

1.1.2 Фенотипические данные

Каждый образец имеет вектор фенотипических признаков:

$$\mathbf{y}_i = (y_{i1}, y_{i2}, \dots, y_{ik})^\top \in \mathbb{R}^k,$$

где k — количество прогнозируемых признаков (в данной работе рассматриваются случаи $k = 2$ и $k = 3$).

1.1.3 Задача многомерной регрессии

Пусть задана обучающая выборка $\{\mathbf{x}_i, \mathbf{y}_i\}_{i=1}^n$, где $\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^m$ — вектор генотипов (SNP-маркеров) i -го образца, $\mathbf{y}_i \in \mathbb{R}^k$ — вектор соответствующих фенотипов. Требуется построить модель

$$f_\theta : \mathcal{X} \rightarrow \mathbb{R}^k,$$

которая по вектору SNP-маркеров $\mathbf{x}$ предсказывает вектор фенотипов $\hat{\mathbf{y}} = f_\theta(\mathbf{x})$. Параметры θ модели выбираются из условия минимизации эмпирического риска:

$$\mathcal{L}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(\mathbf{x}_i), \mathbf{y}_i) \rightarrow \min_{\theta},$$

где $\ell(\cdot, \cdot)$ — функция потерь (в данной работе используется среднеквадратическая ошибка MSE). Усреднение по n образцам позволяет оценить математическое ожидание ошибки на генеральной совокупности и обеспечивает независимость значения функции потерь от объёма выборки.

1.1.4 Обобщённая архитектура модели

Предлагаемая модель f_θ состоит из четырёх последовательных блоков, при этом итоговое предсказание формируется как сумма двух компонент:

$$f_\theta(\mathbf{x}) = P(T(E(\mathbf{x}))) + \lambda \cdot R(T(E(\mathbf{x}))),$$

где:

- $E(\cdot)$ — блок генетического кодирования, преобразующий SNP-вектор $\mathbf{x}$ в эмбединги генов;
- $T(\cdot)$ — трансформерный блок для моделирования межгенных взаимодействий;

- $P(\cdot)$ — блок прогнозирования фенотипов (основная задача);
- $R(\cdot)$ — реконструкционный блок (автокодировщик), выступающий в роли регуляризатора.

Символ «+» в выражении для $f_{\theta}(\mathbf{x})$ означает покомпонентное сложение двух векторов одинаковой размерности: вектора фенотипов из блока P и вектора реконструированных признаков из блока R , умноженного на коэффициент λ . В контексте многозадачного обучения такое сложение позволяет:

- А. одновременно оптимизировать основную задачу (предсказание фенотипов) и вспомогательную задачу (реконструкция входных SNP);
- В. использовать реконструкционный блок как дополнительный регуляризатор, способствующий обучению более информативных эмбедингов генов;
- С. с помощью коэффициента λ регулировать вклад регуляризации в общую функцию потерь.

В данной работе реконструкционный блок используется только на этапе обучения, а при инференсе (прогнозировании) его выход отключается ($\lambda = 0$).

1.1.5 Ключевые модификации

По сравнению с базовой архитектурой в данной модели реализованы следующие усовершенствования:

- А. **Механизм внимания на уровне SNP** — адаптивное взвешивание маркеров внутри каждого гена;
- В. **Реконструкционная регуляризация** — дополнительная потеря на восстановление исходных SNP-данных;
- С. **Многозадачная функция потерь с адаптивным взвешиванием** — автоматическая балансировка вклада различных фенотипов через обучаемые параметры неопределённости.

1.1.6 Анализ существующих решений

Современные методы геномного прогнозирования можно разделить на две основные группы: классические статистические подходы и методы машинного, в частности глубокого, обучения.

Статистические методы. Традиционно для предсказания фенотипов по SNP-данным используются линейные модели, такие как rrBLUP (ridge regression best linear unbiased prediction) [8], GBLUP (genomic best linear unbiased prediction) и байесовские подходы (BGLR) [22]. Эти методы предполагают, что эффекты отдельных SNP аддитивны и независимы, что позволяет эффективно работать с данными, где количество маркеров значительно превышает число наблюдений. Однако они имеют ограниченную способность улавливать нелинейные и эпистатические взаимодействия между генами [13]. Кроме того, методы отбора признаков, такие как анализ главных компонент, могут использоваться для снижения размерности, но при этом теряют часть биологически значимой информации [9].

Методы глубокого обучения. В последние годы всё большее распространение получают нейросетевые архитектуры, способные автоматически извлекать сложные иерархические признаки из геномных данных. Свёрточные нейронные сети (CNN), как в работе [16], эффективны для выявления локальных паттернов, но не всегда учитывают глобальные взаимосвязи между удалёнными генетическими регионами. Результаты исследований показывают, что CNN могут быть успешно применены для прогнозирования признаков нута с использованием комбинации SNP и физических расстояний [21].

Трансформерные архитектуры. Особый интерес представляют модели на основе трансформеров, которые благодаря механизму многоголового внимания [2] позволяют моделировать сложные взаимодействия между любыми элементами входной последовательности. В задаче геномного прогнозирования трансформеры продемонстрировали высокую эффективность для предсказания устойчивости ячменя к фузариозу [15] и для выявления зависимостей между SNP-маркерами [1]. Обобщение этих подходов рассмотрено в работе [26], где обсуждается применение больших языковых моделей для анализа генома.

Работа Реутова и базовые архитектуры. Непосредственным предшественником данной работы является исследование [24], в котором была разработана модель прогнозирования признаков нута (масса тысячи семян, высота растения, биомасса) с использованием трансформерной архитектуры. В этой работе была предложена агрегация SNP-маркеров по генам с помощью свёртки, а также исследованы методы аугментации данных (shuffle и mixup). Сравнительный анализ показал, что

метод *mixup* с долей аугментированных данных 0.4 позволяет повысить точность предсказания фенотипов, особенно для сложных признаков. Однако в модели [24] использовалась свёрточная агрегация SNP, не учитывающая относительную важность отдельных маркеров внутри гена. Это ограничение послужило одним из мотивов для разработки предлагаемой в данной работе архитектуры с механизмом внимания на уровне SNP.

Выявление генных взаимодействий. Для интерпретации моделей глубокого обучения и выявления значимых генов и их взаимодействий широко применяются значения Шепли [19; 25]. В задаче детекции парных генных взаимодействий этот подход был адаптирован и показал свою эффективность для выявления синергетических и антагонистических эффектов [11]. В работе предшественника [24] значения Шепли были использованы для оценки центральности генов и построения матриц взаимодействий для фенотипов TSW и Ptht нута, что позволило идентифицировать ключевые гены-«хабы».

Обоснование предлагаемых модификаций. Таким образом, анализ существующих решений выявляет следующие нерешённые проблемы и направления для улучшения:

- А. Большинство трансформерных моделей для геномного прогнозирования используют агрегацию SNP-маркеров на уровне генов без учёта индивидуальной важности каждого маркера (свёртка или усреднение).
- В. Регуляризация скрытых представлений генов остаётся недостаточно изученной; стандартные методы (dropout, weight decay) не всегда предотвращают переобучение при малых выборках.
- С. Отсутствуют систематические сравнения стратегий отбора генов (взвешенной, равномерной по геному, равномерной по хромосомам) для трансформерных архитектур.
- Д. Интерпретация выявленных генных взаимодействий требует дальнейшей валидации и сопоставления с биологическими базами данных.

Предлагаемая в данной работе модель направлена на решение этих проблем за счёт введения механизма внимания на уровне SNP, реконструкционной регуляризации и адаптивного взвешивания фенотипических признаков.

Таблица 1.1

Сводная статистика по датасетам нута

Датасет	Образцов	TSW (среднее $\pm$ std)	Ptht (среднее $\pm$ std)	Диапазон TSW
2016	407	223.35 $\pm$ 86.84	54.34 $\pm$ 8.31	[90.0, 475.0]
2017	146	222.09 $\pm$ 83.11	53.66 $\pm$ 6.12	[60.0, 435.0]
2022_AOS	113	245.98 $\pm$ 84.94	50.67 $\pm$ 9.99	[69.8, 450.6]
Всего	666	226.92 $\pm$ 85.96	53.57 $\pm$ 8.30	[60.0, 475.0]

1.2 Описание данных

1.2.1 Данные по нуту

В исследовании использовались генотипические и фенотипические данные по образцам нута (*Cicer arietinum*), собранные в различные годы: 2016, 2017 и 2022 (два набора — Астраханская опытная станция (AOS) и Кубанская опытная станция (KOS)). Данные были предоставлены Всероссийским институтом растениеводства им. Н.И. Вавилова (ВИР) и обработаны в Санкт-Петербургском политехническом университете Петра Великого (СПбПУ). Подробное описание этих данных приведено в работе [24], где они использовались для первоначальной апробации базовой архитектуры.

Каждый образец характеризуется набором из 5783 однонуклеотидных полиморфизмов (SNP), аннотированных к конкретным генным регионам, а также тремя количественными фенотипическими признаками:

- **TSW (Thousand Seed Weight)** — масса тысячи семян (г);
- **Ptht (Plant Height)** — высота растения (см);
- **Bvld (Biological Yield)** — биомасса всего растения (г).

SNP-маркеры закодированы численно в соответствии с типом аллеля: 2 — минорная гомозигота (*aa*), 1 — гетерозигота (*Aa*), 0 — мажорная гомозигота (*AA*). Данные по фенотипам Ptht и Bvld представлены средними значениями по пяти растениям для каждого образца.

Для обучения и тестирования модели использовались данные 2016 и 2017 годов как наиболее согласованные по распределению признаков. Обучающая выборка составила 442 образца, тестовая — 99 образцов. Статистические характеристики данных приведены в таблице 1.1.

1.2.2 Данные по рису

Для оценки обобщающей способности разработанной архитектуры были использованы генотипические и фенотипические данные риса (*Oryza sativa*). Данные получены из открытых источников [12] и предварительно обработаны для обеспечения совместимости с архитектурой модели.

Датасет по рису содержит следующие компоненты:

А. Фенотипические данные:

- Количество образцов: 469
- Фенотипические признаки:
 - Высота растения (*Plant height*) [см]
 - Число побегов (*Tiller number*)
- Дополнительные признаки: угол побега, параметры флагового листа, параметры метёлки и др.

В. Генотипические данные:

- Количество образцов: 523
- Количество SNP-маркеров: 4 045
- Формат кодирования: численное представление аллелей (0, 1, 2)
- Идентификаторы SNP: gwseq-rs1, gwseq-rs10, seq-rs992 и др.

С. Аннотационные данные:

- Координаты SNP: 4 136 записей с информацией о хромосоме и позиции
- Генные позиции: 211 705 генов с указанием хромосомы, начала и конца
- Сопоставление SNP с генами: 15 653 соответствий между SNP и генами

Статистические характеристики данных После объединения генотипических и фенотипических данных и фильтрации общих образцов получен датасет размерностью $469 \times 4\,045$ SNP-признаков и 2 целевых фенотипических признаков.

Статистические характеристики фенотипических признаков представлены в таблице 1.2.

Таблица 1.2

Статистические характеристики фенотипических данных риса

Параметр	Plant height (cm)	Tiller number
Количество образцов	469	469
Минимальное значение	54.50	4.67
Максимальное значение	199.50	26.50
Среднее значение	110.93	12.43
Стандартное отклонение	24.57	3.18
Медиана	111.20	12.00
Коэффициент вариации, %	22.15	25.61

Для высоты растения наблюдается распределение, близкое к нормальному, с центром в районе 110 см. Распределение числа побегов имеет положительную асимметрию с концентрацией значений в диапазоне 10–15 побегов.

Корреляционная структура данных Между целевыми фенотипическими признаками наблюдается умеренная отрицательная корреляция. Коэффициент корреляции Пирсона составил:

$$r_{\text{Plant height} \times \text{Tiller number}} = -0.348 \quad (p < 0.001)$$

Это указывает на существование биологической связи между высотой растения и числом побегов: более высокие растения имеют тенденцию к образованию меньшего числа побегов.

Предобработка данных Перед подачей данных в модель необходимо выполнить ряд шагов предобработки, которые являются неотъемлемой частью разработанной архитектуры.

Частотное кодирование SNP Значения SNP, изначально закодированные как $\{0, 1, 2\}$, преобразуются в частоту встречаемости соответствующего аллеля в обучающей выборке. Для каждого SNP-маркера j вычисляется:

$$f_j(a) = \frac{n_j(a)}{N_{\text{train}}}, \quad a \in \{0, 1, 2\},$$

где $n_j(a)$ — количество образцов в обучающей выборке со значением a для SNP j , N_{train} — общее количество образцов в обучающей выборке. Тогда преобразованное

значение для образца i и SNP j составляет:

$$x'_{ij} = f_j(x_{ij}) = \frac{n_j(x_{ij})}{N_{\text{train}}}.$$

Такое кодирование позволяет модели учитывать редкость или распространённость конкретного аллеля в популяции.

Объединение данных и разделение на выборки После кодирования выполняется объединение генотипических и фенотипических данных по идентификаторам образцов. Далее данные разделяются на три выборки: 80% — обучающая, 10% — валидационная, 10% — тестовая.

Аугментация методом MixUp Для увеличения объёма обучающей выборки и улучшения обобщающей способности модели применяется метод MixUp. Для случайно выбранной пары образцов $(\mathbf{x}_i, \mathbf{y}_i)$ и $(\mathbf{x}_j, \mathbf{y}_j)$ синтетический пример генерируется следующим образом:

$$\tilde{\mathbf{x}} = \lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j,$$

$$\tilde{\mathbf{y}} = \lambda \mathbf{y}_i + (1 - \lambda) \mathbf{y}_j,$$

где $\lambda \in [0, 1]$ — параметр смешивания. В данной работе используется фиксированное значение $\lambda = 0.0625$.

Преобразование SNP $\rightarrow$ Gene Ключевым этапом предобработки, специфичным для разработанной архитектуры, является преобразование данных с уровня отдельных SNP на уровень генов. Для этого на основе таблицы аннотации SNP-маркеров к генам каждому SNP сопоставляется соответствующий ген. В результате формируется отображение SNP $\rightarrow$ Gene, которое используется блоком генетического кодирования для агрегации SNP-признаков в эмбединги генов.

Данное преобразование позволяет:

- сократить размерность признакового пространства;
- учесть биологическую иерархию генетической информации;
- обеспечить интерпретируемость модели на уровне генов, а не отдельных SNP.

Для данных по рису результаты преобразования выглядят следующим образом:

- Всего сопоставлений SNP-ген: 15 653;

- Уникальных генов: 3 918;
- Среднее количество SNP на ген: ≈ 4.0 ;

Таким образом, размерность признакового пространства сокращается с 4 045 SNP-признаков до 3 918 ген-признаков. Важно отметить, что плотность SNP на ген в данных риса составляет всего около 1.07 после фильтрации аннотированных маркеров, что создаёт дополнительные сложности для агрегации.

Итоговые размерности данных После выполнения всех шагов предобработки получены следующие размерности:

- Признаки: $\mathbf{X} \in \mathbb{R}^{469 \times 4045}$
- Целевые переменные: $\mathbf{y} \in \mathbb{R}^{469 \times 2}$

1.2.3 Данные по рапсу

Для исследования эффективности предложенных архитектурных решений на данных с высокой плотностью SNP-маркеров были использованы генотипические и фенотипические данные рапса (*Brassica napus*). Данные получены из базы CropGS-Hub [4] (коhortа GSTP010), содержащей результаты полногеномного секвенирования 991 образца из 39 стран.

SNP-маркеры в данных CropGS-Hub имеют имена, отражающие их локализацию. Например:

chrA01_17073

где chrA01 — хромосома (A01 рапса), а 17073 — позиция на хромосоме в парах оснований.

Основные характеристики генетических данных:

- Количество образцов: 991
- Количество SNP: 1 272 066 уникальных
- Количество генов с аннотацией: 60 768
- Покрытие аннотацией: 100%
- Среднее количество SNP на ген: 21.3
- Медиана SNP на ген: 16
- Максимум SNP на ген: 745

Данные соответствуют описанию в статье [27], где 991 образец рапса были секвенированы со средней глубиной 6.6×, а SNP вызывались с использованием эталонного генома Darmor-bzh.




Рис.1.1. Распределение количества SNP на ген в данных рапса

Распределение SNP по генам Распределение количества SNP на ген (рис. 1.1) является асимметричным: большинство генов содержат от 3 до 28 SNP, при этом встречаются гены с очень большим числом маркеров (до 745). Такая вариативность критически важна для блока кодирования, где механизм внимания должен адаптивно обрабатывать гены с разным количеством SNP.

Распределение по хромосомам Данные охватывают 19 хромосом (A01–A10, C01–C09). Распределение SNP и генов по хромосомам представлено на рисунке 1.2. Наибольшее количество SNP сосредоточено на хромосомах A03 и C03, что соответствует их длине и плотности генов. Плотность SNP на ген варьируется от 21.7 до 24.0, что говорит о примерно равномерном покрытии генов маркерами по хромосомам.

Позиции SNP внутри генов Для позиционного кодирования важны относительные позиции SNP внутри генов. Как показано на рисунке 1.3, распределение близко к равномерному (среднее 0.5003, медиана 0.5007), что является благоприятным фактором для использования тригонометрических функций в позиционном кодировании.

Расстояния до генов Значительная часть SNP (60 236 SNP) находятся в промоторной области (расстояние до старта гена > 0). На рисунке 1.4 представлено распределение расстояний до начала и конца гена. Медианное расстояние до старта составляет 1482 п.н., что может быть учтено при построении позиционного кодирования как дополнительный признак.




Рис.1.2. Распределение SNP и генов по хромосомам рапса




Рис.1.3. Распределение относительных позиций SNP внутри генов рапса




Рис.1.4. Распределение расстояний до начала и конца гена (логарифмическая шкала)

Таблица 1.3

Основные фенотипические признаки рапса в данных CropGS-Hub

Категория	Признаки
Время цветения	FloweringTime (от всходов до цветения)
Качество семян	OilContent, ProteinContent, GlucosinolateContent
Жирные кислоты	C16:0, C18:1, C18:2, C18:3, C20:1, C22:1
Другие	Высота растения, масса семян и др.

SNP, относящиеся к нескольким генам В данных обнаружено 22 706 SNP (1.78% от общего числа), которые отнесены к нескольким генам. Это явление может быть обусловлено перекрывающимися генами, расположением SNP в регуляторных областях, особенностями аннотации генома, а также аллополиплоидной природой рапса (наличие А и С субгеномов). В данной работе для обработки таких SNP используется стратегия выбора гена с минимальным расстоянием до SNP.

Фенотипические признаки Фенотипические данные рапса включают широкий спектр признаков (табл. 1.3):

Для данной работы наибольший интерес представляют признаки, сопоставимые с исследованными ранее для нута: время цветения (FloweringTime) коррелирует с фенологическими сроками, содержание масла (OilContent) и белка (ProteinContent) отражают продуктивность и качество семян, а высота растения (Plant height) является важным морфологическим признаком.

Пропуски в данных На рисунке 1.5 показана доля пропущенных значений по признакам. Большинство признаков имеют пропуски на уровне 70–80%, что связано с тем, что не для всех линий были проведены соответствующие биохимические




Рис.1.5. Доля пропущенных значений по признакам рапса

Таблица 1.4

Сравнительная характеристика наборов данных

Параметр	Нут	Рис	Рапс
Образцов	553	469	991
SNP (после фильтрации)	5 783	1 708	1 272 066
Генов (уникальных)	2 837	1 599	60 768
Среднее SNP/ген	2.04	1.07	21.3
Покрывтие аннотацией	100%	42%	100%
Основные признаки	TSW, Ptht, Blvd	Plant height, Tiller number	FloweringTime, OilContent, GlucosinolateContent
Источник	ВИР / СПбПУ	Lu et al. (2015)	CropGS-Hub (Wu et al., 2019)

анализы. Исключение составляет время цветения (FloweringTime), для которого пропуски составляют лишь 6.6% (65 из 991 образца). Это делает данный признак наиболее пригодным для обучения и послужило основанием для использования его в качестве основной целевой переменной.

1.2.4 Сравнительная характеристика наборов данных

Для наглядного сопоставления трёх использованных наборов данных в таблице 1.4 сведены их основные параметры.

Как видно из таблицы, наборы данных существенно различаются по плотности SNP на ген: от крайне низкой у риса (1.07) до высокой у рапса (21.3). Это позволяет провести кросс-культурный анализ и оценить, как плотность маркеров влияет на эффективность предложенных архитектурных решений, в частности механизма внимания на уровне SNP.

1.2.5 Выводы по главе 1

В данной главе сформулирована задача многомерной регрессии для прогнозирования фенотипов по SNP-данным. Представлена обобщённая архитектура модели, включающая четыре блока: кодирования с вниманием на уровне SNP, трансформерный, прогнозирования и реконструкционный. Описаны три набора данных (нут, рис, рапс), существенно различающиеся по плотности SNP на ген и набору целевых признаков, что позволит в дальнейшем провести кросс-культурный анализ и оценить обобщающую способность разработанной модели.

2 РАЗРАБОТКА АРХИТЕКТУРЫ МОДЕЛИ И ОПИСАНИЕ ИСПОЛЬЗУЕМЫХ МЕТОДОВ

В данной главе представлена разработанная архитектура модели глубокого обучения для прогнозирования фенотипических признаков по SNP-данным. Подробно описываются все компоненты предложенной модели: блок генетического кодирования, трансформерный блок, блок прогнозирования, а также реконструкционный блок, выполняющий функцию регуляризации. Для каждого блока приводится математическое описание преобразований и обоснование принятых архитектурных решений. Помимо архитектуры, в главе рассматриваются методы аугментации данных и настройки процесса обучения. В параграфе 2.1 представлено детальное описание архитектуры модели и её ключевых компонентов.[28]

2.1 Архитектура модели

Разработанная модель реализована с использованием библиотеки PyTorch и представляет собой последовательное соединение четырёх основных логических




Рис.2.1. Общая архитектура предложенной модели

блоков, которые преобразуют исходные SNP-данные в предсказания фенотипических признаков. Общая схема архитектуры показана на рисунке 2.1.

2.1.1 Блок генетического кодирования (*GeneticEncodingBlock*)

Блок генетического кодирования выполняет преобразование входных SNP-данных в векторные представления на уровне генов. Основная задача этого блока состоит в агрегировании информации о SNP, относящихся к одному гену, с учётом их значений, позиционной информации и обучаемых весов.

Сопоставление SNP с генами На первом этапе блок использует таблицу соответствия SNP генам, которая формируется на основе аннотации генома. Для каждого SNP определяется ген, к которому он относится (т.е. в пределах которого или в регуляторной области которого данный SNP локализован), после чего строится структура данных, позволяющая группировать SNP по соответствующим

генам. Пусть G — множество всех генов, $|G| = N_{\text{genes}}$. Для каждого гена $g \in G$ определено множество индексов SNP $S_g = \{i : \text{SNP}_i \text{ относится к гену } g\}$.

Частотное кодирование SNP Перед агрегацией значения SNP подвергаются частотному кодированию. Исходные значения $\{0,1,2\}$ заменяются частотами встречаемости соответствующих аллелей в обучающей выборке:

$$\tilde{x}_{ij} = \frac{\text{count}(x_{ij})}{n},$$

где $\text{count}(x_{ij})$ — количество образцов со значением x_{ij} для j -го SNP. Такое кодирование позволяет привести данные к единому масштабу и учесть редкость некоторых аллелей.

Механизм внимания на уровне SNP Ключевой особенностью разработанной модели является использование механизма внимания для адаптивной агрегации SNP внутри каждого гена. В отличие от простого усреднения или свёртки, механизм внимания позволяет модели выделять наиболее информативные SNP-маркеры и подавлять шумовые компоненты.

Для каждого гена g и относящегося к нему SNP $s \in S_g$ формируется векторное представление:

$$\mathbf{h}_{gs} = \tilde{x}_{gs} \cdot \mathbf{w}_{\text{snp}}, \quad \mathbf{w}_{\text{snp}} \in \mathbb{R}^d,$$

где d — размерность эмбединга, $\mathbf{w}_{\text{snp}}$ — обучаемый вектор, общий для всех SNP. Далее для каждого SNP вычисляется скалярная оценка важности:

$$e_{gs} = \mathbf{a}^\top \mathbf{h}_{gs}, \quad \mathbf{a} \in \mathbb{R}^d,$$

где $\mathbf{a}$ — обучаемый вектор параметров внимания. Нормированные коэффициенты внимания получаются применением функции softmax:

$$\alpha_{gs} = \frac{\exp(e_{gs})}{\sum_{k \in S_g} \exp(e_{gk})}.$$

Адаптивное представление гена формируется как взвешенная сумма векторных представлений SNP:

$$\mathbf{v}_g = \sum_{s \in S_g} \alpha_{gs} \mathbf{h}_{gs}.$$

Такой подход позволяет модели самостоятельно определять, какие SNP вносят наибольший вклад в формирование фенотипического признака, и усиливать их сигнал.

Обучаемые эмбединги генов Каждый ген имеет собственный обучаемый эмбединг $\mathbf{e}_g \in \mathbb{R}^d$, который позволяет модели учитывать индивидуальные особенности гена, не зависящие от конкретных SNP-значений в образце.

Позиционное кодирование Для учёта физического расположения генов на хромосомах используется позиционное кодирование. В отличие от стандартного подхода, в данной работе позиция гена масштабируется с учётом его средней SNP-активности:

$$p_g^{\text{scaled}} = \rho \cdot \text{pos}_g \cdot \exp(\bar{x}_g),$$

где pos_g — репрезентативная позиция гена на хромосоме, вычисляемая как среднее арифметическое координат начала и конца кодирующей области: $\text{pos}_g = (\text{start}_g + \text{end}_g)/2$; $\bar{x}_g = \frac{1}{|S_g|} \sum_{s \in S_g} \tilde{x}_{gs}$ — среднее значение SNP в гене, ρ — масштабирующий коэффициент.

Позиционное кодирование для g -го гена и j -й координаты эмбединга вычисляется по формулам:

$$\text{PE}_{g,2k} = \sin \left(p_g^{\text{scaled}} \cdot \exp \left(-\frac{\ln 10^5}{d} \cdot k \right) \right),$$

$$\text{PE}_{g,2k+1} = \cos \left(p_g^{\text{scaled}} \cdot \exp \left(-\frac{\ln 10^5}{d} \cdot k \right) \right),$$

где $k = 0, 1, \dots, d/2 - 1$. Такое кодирование позволяет модели различать гены по их хромосомному положению, при этом гены с более высокой вариативностью SNP получают усиленный позиционный сигнал.

Итоговое представление гена Финальное представление гена формируется как сумма трёх компонентов:

$$\mathbf{z}_g = \mathbf{v}_g + \mathbf{e}_g + \mathbf{PE}_g,$$

где $\mathbf{v}_g$ — агрегированное SNP-представление, $\mathbf{e}_g$ — обучаемый эмбединг гена, $\mathbf{PE}_g$ — позиционное кодирование.

Для стабилизации обучения после суммирования применяется Layer Normalization:

$$\mathbf{z}_g^{\text{norm}} = \text{LayerNorm}(\mathbf{z}_g).$$

Выходом блока генетического кодирования является тензор размерности $[B, N_{\text{genes}}, d]$, где B — размер батча (количество образцов растений в одной

итерации обучения), N_{genes} — количество генов, d — размерность эмбединга. Таким образом, для каждого образца формируется матрица признаков размера $N_{\text{genes}} \times d$, которая затем поступает на вход трансформерному блоку.

2.1.2 Трансформерный блок (TransformerBlock)

Трансформерный блок предназначен для моделирования сложных межгеновых взаимодействий. Он обрабатывает последовательность векторных представлений генов и выявляет зависимости между удалёнными генетическими регионами.

Механизм многоголового самовнимания В основе трансформерного блока лежит механизм многоголового самовнимания.[2] Для входной последовательности $\mathbf{Z} \in \mathbb{R}^{B \times N_{\text{genes}} \times d}$ вычисляются три матрицы: запросов $\mathbf{Q}$, ключей $\mathbf{K}$ и значений $\mathbf{V}$:

$$\mathbf{Q} = \mathbf{Z}\mathbf{W}^Q, \quad \mathbf{K} = \mathbf{Z}\mathbf{W}^K, \quad \mathbf{V} = \mathbf{Z}\mathbf{W}^V,$$

где $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V \in \mathbb{R}^{d \times d}$ — обучаемые матрицы проекций.

Внимание для одной головы вычисляется как:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V},$$

где $d_k = d/h$ — размерность головы, h — количество голов внимания.

Механизм многоголовости позволяет модели анализировать взаимосвязи между генами с разных ракурсов:

$$\text{MultiHead}(\mathbf{Z}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O,$$

где каждая голова работает со своей проекцией входных данных, а $\mathbf{W}^O \in \mathbb{R}^{d \times d}$ — обучаемая матрица проекции объединённого результата.

Механизм dropout Для предотвращения переобучения в каждом слое трансформера используется механизм dropout [6]. Dropout случайным образом обнуляет долю нейронов (с вероятностью $p_{\text{dropout}} = 0.2$) на каждой итерации обучения, что вынуждает сеть не полагаться на отдельные нейроны и способствует формированию более робастных представлений.

Полносвязная сеть После слоя внимания результат проходит через двухслойную полносвязную сеть с функцией активации GELU:

$$\text{FFN}(\mathbf{X}) = \text{GELU}(\mathbf{X}\mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2,$$

где $\mathbf{W}_1 \in \mathbb{R}^{d \times d_{\text{ff}}}$, $\mathbf{W}_2 \in \mathbb{R}^{d_{\text{ff}} \times d}$, d_{ff} — размерность скрытого слоя feed-forward сети.

Остаточные соединения и нормализация Для улучшения сходимости и предотвращения затухания градиентов используются остаточные соединения и Layer Normalization. Каждый подблок трансформера имеет структуру:

$$\mathbf{Z}' = \text{LayerNorm}(\mathbf{Z} + \text{MultiHead}(\mathbf{Z})),$$

$$\mathbf{Z}'' = \text{LayerNorm}(\mathbf{Z}' + \text{FFN}(\mathbf{Z}')).$$

Выходом трансформерного блока является тензор той же размерности $[B, N_{\text{genes}}, d]$, содержащий контекстуализированные представления генов с учётом их взаимосвязей.

2.1.3 Блок прогнозирования (*PredictionBlock*)

Блок прогнозирования преобразует выход трансформера в предсказания фенотипических признаков. В отличие от базовой архитектуры, где применялось прямое разворачивание всех генов в вектор, в данной работе используется гибридный механизм агрегации.

Гибридная агрегация с CLS-токеном В начало последовательности генов добавляется специальный CLS-токен, который агрегирует глобальную информацию о геноме. После обработки трансформером этот токен содержит контекстуализированное представление всего генома.

Пусть $\mathbf{z}_{\text{CLS}}$ — представление CLS-токена, а $\{\mathbf{z}_g\}_{g=1}^{N_{\text{genes}}}$ — представления генов после трансформерного блока. Вычисляются веса внимания для генов:

$$a_g = \frac{\exp(\mathbf{u}^\top \mathbf{z}_g)}{\sum_{k=1}^{N_{\text{genes}}} \exp(\mathbf{u}^\top \mathbf{z}_k)}, \quad \mathbf{u} \in \mathbb{R}^d,$$

$$\mathbf{z}_{\text{attn}} = \sum_{g=1}^{N_{\text{genes}}} a_g \mathbf{z}_g.$$

Итоговое агрегированное представление формируется как взвешенная сумма представления CLS-токена и представления, полученного с помощью механизма внимания:

$$\mathbf{z}_{\text{final}} = \alpha \cdot \mathbf{z}_{\text{CLS}} + (1 - \alpha) \cdot \mathbf{z}_{\text{attn}},$$

где $\alpha \in [0,1]$ — обучаемый параметр баланса.

Регрессионная головка Финальное представление подаётся на вход двухслойного перцептрона:

$$\mathbf{h} = \text{ReLU}(\mathbf{W}_1 \mathbf{z}_{\text{final}} + \mathbf{b}_1), \quad \mathbf{h} \in \mathbb{R}^{256},$$

$$\hat{\mathbf{y}} = \mathbf{W}_2 \mathbf{h} + \mathbf{b}_2, \quad \hat{\mathbf{y}} \in \mathbb{R}^k,$$

где k — количество прогнозируемых фенотипов. Размерность скрытого слоя (256) подобрана эмпирически как компромисс между выразительной способностью и склонностью к переобучению.

2.1.4 Реконструкционный блок (*ReconstructionHead*)

Реконструкционный блок является регуляризирующим компонентом модели. Он пытается восстановить исходные SNP-данные по агрегированным представлениям генов, что вынуждает модель сохранять информативность промежуточных представлений.

Пусть $\mathbf{Z} \in \mathbb{R}^{B \times N_{\text{genes}} \times d}$ — выход трансформерного блока. Представление разворачивается в одномерный вектор:

$$\mathbf{z}_{\text{flat}} = \text{Flatten}(\mathbf{Z}) \in \mathbb{R}^{B \times (N_{\text{genes}} \cdot d)}.$$

Затем применяется двухслойный перцептрон:

$$\mathbf{h}_{\text{recon}} = \text{ReLU}(\mathbf{W}_1^{\text{recon}} \mathbf{z}_{\text{flat}} + \mathbf{b}_1^{\text{recon}}), \quad \mathbf{h}_{\text{recon}} \in \mathbb{R}^{512},$$

$$\hat{\mathbf{X}} = \mathbf{W}_2^{\text{recon}} \mathbf{h}_{\text{recon}} + \mathbf{b}_2^{\text{recon}}, \quad \hat{\mathbf{X}} \in \mathbb{R}^{B \times M},$$

где M — количество SNP-маркеров. Ошибка реконструкции вычисляется как среднеквадратичная ошибка между исходными и восстановленными SNP-значениями.

Данный блок активен только на этапе обучения, а его вклад в общую функцию потерь регулируется монотонно убывающим коэффициентом, что позволяет на ранних этапах обучения сильнее регуляризовать модель, а на поздних — сосредоточиться на основной задаче прогнозирования.

Регуляризация в блоке предсказания В блоке предсказания также применяется dropout с вероятностью $p_{\text{dropout}} = 0.3$ после первого полносвязного слоя и перед функцией активации ReLU. Более высокая вероятность отключения (по сравнению с трансформерным блоком) обусловлена тем, что в данном блоке сосредоточено наибольшее количество параметров модели, и он наиболее подвержен переобучению.

2.1.5 Количество параметров модели

Оценка вычислительной сложности предложенной модели показывает, что общее количество обучаемых параметров зависит от следующих размерностей:

- N_{SNP} — количество SNP-маркеров;
- N_{genes} — количество генов;
- d — размерность эмбединга;
- L — количество слоёв трансформера;
- d_{ff} — размер скрытого слоя в трансформере;
- N_{classes} — количество прогнозируемых фенотипов.

Блок генетического кодирования (GeneticEncodingBlock) Параметры этого блока включают обучаемый вектор $\mathbf{w}_{\text{snp}} \in \mathbb{R}^d$ (проекция SNP-значений), параметры механизма внимания ($\mathbf{a} \in \mathbb{R}^d$), а также эмбединги генов $\mathbf{e}_g \in \mathbb{R}^d$ для каждого гена:

$$\text{Params}_{\text{GEB}} = \underbrace{2d}_{\mathbf{w}_{\text{snp}}, \mathbf{a}} + \underbrace{N_{\text{genes}} \cdot d}_{\text{эмбединги генов}}.$$

Трансформерный блок (TransformerBlock) Параметры трансформера определяются размерностью эмбединга d , количеством голов внимания H и размерностью скрытого слоя d_{ff} . Для одного слоя количество параметров составляет:

$$\text{Params}_{\text{layer}} = 4d^2 + 2d \cdot d_{\text{ff}} + 4d,$$

где $4d^2$ приходится на механизм внимания (проекции Q , K , V и выходная), $2d \cdot d_{\text{ff}}$ — на полносвязные слои, $4d$ — на смещения (bias). Для L слоёв:

$$\text{Params}_{\text{TB}} = L \cdot (4d^2 + 2d \cdot d_{\text{ff}} + 4d).$$

Блок прогнозирования (PredictionBlock) Данный блок содержит два полносвязных слоя:

$$\text{Params}_{\text{PB}} = (d \cdot N_{\text{genes}}) \cdot d_{\text{hidden}} + d_{\text{hidden}} \cdot N_{\text{classes}},$$

где d_{hidden} — размер скрытого слоя (в данной работе $d_{\text{hidden}} = 32$).

Голова реконструкции (ReconstructionHead) Голова реконструкции также состоит из двух полносвязных слоёв:

$$\text{Params}_{\text{RH}} = (d \cdot N_{\text{genes}}) \cdot d_{\text{recon}} + d_{\text{recon}} \cdot N_{\text{SNP}},$$

где d_{recon} — размер скрытого слоя реконструкции (в данной работе $d_{\text{recon}} = 512$).

Пример численных значений Для эксперимента на данных рапса с параметрами: $N_{\text{SNP}} = 1\,272\,066$, $N_{\text{genes}} = 3\,000$, $d = 48$, $L = 4$, $d_{\text{ff}} = 128$, $N_{\text{classes}} = 2$, $d_{\text{hidden}} = 32$, $d_{\text{recon}} = 512$ — общее количество обучаемых параметров составляет 80 864 527. Распределение параметров по блокам представлено в таблице 2.1.

Таблица 2.1

Распределение обучаемых параметров по блокам модели

Блок модели	Количество параметров	Доля, %
GeneticEncodingBlock	102 400	0.13
TransformerBlock	91 712	0.11
PredictionBlock	26 198 786	32.39
ReconstructionHead	54 471 629	67.37
Всего	80 864 527	100.00

Подавляющая часть параметров сосредоточена в блоках прогнозирования и реконструкции, что характерно для архитектур, работающих с высокоразмерными векторными представлениями. При этом параметры блоков кодирования и трансформера зависят от N_{genes} и d , но не от N_{SNP} , что позволяет масштабировать модель на данные с большим количеством SNP без существенного увеличения вычислительной сложности этих блоков.

2.1.6 Аугментация данных

Аугментация данных является важным инструментом для увеличения объёма и разнообразия обучающей выборки, что особенно актуально в задачах геномного прогнозирования, где количество доступных образцов часто ограничено. Применение аугментации позволяет снизить риск переобучения, повысить устойчивость модели к шуму и улучшить обобщающую способность.

В данной работе исследованы два метода аугментации, адаптированных для работы с SNP-данными: аугментация перестановкой хромосом (shuffle) и аугментация смешиванием (mixup). Оба метода сохраняют биологическую достоверность генерируемых примеров.

Аугментация перестановкой (shuffle) Метод основан на предположении, что порядок следования хромосом в последовательности SNP не несёт биологической

значимости и может быть произвольно изменён без потери информативности данных [16]. Для каждого исходного образца создаётся синтетическая версия путём случайной перестановки блоков SNP, соответствующих разным хромосомам.

Пусть исходный вектор SNP-маркеров образца имеет вид:

$$\mathbf{x} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(C)}],$$

где C — количество хромосом, $\mathbf{x}^{(c)}$ — вектор SNP, принадлежащих c -й хромосоме. Аугментированный вектор формируется как:

$$\tilde{\mathbf{x}} = [\mathbf{x}^{(\pi(1))}, \mathbf{x}^{(\pi(2))}, \dots, \mathbf{x}^{(\pi(C))}],$$

где π — случайная перестановка индексов хромосом. Целевое значение при этом остаётся неизменным: $\tilde{y} = y$.

Данный подход позволяет:

- увеличить объём обучающей выборки без привлечения дополнительных данных;
- снизить чувствительность модели к порядку входных признаков.

Аугментация смешиванием (mixup) Метод mixup основан на линейной интерполяции пар образцов и их целевых значений [5; 20]. Для двух случайно выбранных образцов $(\mathbf{x}_i, y_i)$ и $(\mathbf{x}_j, y_j)$ из обучающей выборки синтетический образец генерируется по формулам:

$$\tilde{\mathbf{x}} = \lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j,$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j,$$

где $\lambda \sim \text{Beta}(\alpha, \alpha)$ — параметр смешивания, α — гиперпараметр распределения. При $\alpha = 1$ распределение Beta превращается в равномерное на отрезке $[0,1]$. В данной работе использовалось значение $\alpha = 0.3$, что соответствует генерации λ в окрестности значения 0.5.

Для повышения разнообразия генерируемых данных в данной работе применяется модифицированная версия mixup с добавлением шума:

$$\tilde{\mathbf{x}} = (0.95 + 0.05 \cdot \xi) \cdot (\lambda \mathbf{x}_i + (1 - \lambda) \mathbf{x}_j),$$

где $\xi \sim \mathcal{U}(0,1)$ — случайная величина, равномерно распределённая на отрезке $[0,1]$. Такая модификация позволяет генерировать более разнообразные синтетические образцы и улучшает обобщающую способность модели.

Сравнительный анализ методов аугментации Для оценки эффективности методов аугментации были проведены эксперименты с использованием простых моделей: линейной регрессии, rrBLUP и BGLR. Оценка качества производилась по двум метрикам: нормализованной среднеквадратической ошибке (NRMSE) и средней абсолютной арктангенсной процентной ошибке (MAAPE).

Метрика NRMSE вычисляется как:

$$\text{NRMSE} = \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\bar{y}},$$

где $\bar{y}$ — среднее значение целевой переменной.

Метрика MAAPE, являющаяся более устойчивой альтернативой MAPE, вычисляется по формуле:

$$\text{MAAPE} = \frac{1}{n} \sum_{i=1}^n \arctan \left| \frac{y_i - \hat{y}_i}{y_i} \right|.$$

Результаты экспериментов, проведённых в работе [24], показали, что метод *mixur* демонстрирует более низкие значения ошибок по сравнению с аугментацией перестановкой для всех рассмотренных моделей (линейная регрессия, rrBLUP и BGLR). Оптимальные результаты достигаются при доле аугментированных данных в диапазоне от 0.3 до 0.7 от размера исходной обучающей выборки. В данной работе для всех последующих экспериментов использовался метод *mixur* с параметром $\lambda = 0.3$ и коэффициентом аугментации 0.5.

2.1.7 Стратегии отбора генов

В ситуациях, когда полный набор генов слишком велик для эффективного обучения (например, в случае рапса с 60 768 генами), возникает необходимость в отборе подмножества наиболее информативных генов. Неправильный выбор стратегии отбора может привести к потере ключевой генетической информации или к переобучению модели. В данной работе исследованы четыре основные стратегии отбора генов.

Взвешенный отбор (weighted selection) Данная стратегия основана на распределении количества SNP на ген. Все гены ранжируются по убыванию количества SNP и разбиваются на четыре квантили. Целевое распределение количества отбираемых генов задаётся весами: первый квантиль (гены с наименьшим количеством SNP)

получает вес 0.1, второй — 0.2, третий — 0.3, четвёртый (гены с наибольшим количеством SNP) — 0.4. Такой подход позволяет сфокусироваться на генах с большим количеством маркеров, которые потенциально несут больше генетической информации.

Математически, если N — общее количество отбираемых генов, Q_i — количество генов в i -м квантиле, w_i — вес квантиля, то количество генов, отбираемых из i -го квантиля, составляет:

$$n_i = \left\lfloor N \cdot \frac{w_i}{\sum_{j=1}^4 w_j} \right\rfloor.$$

Равномерный отбор по геному (uniform position selection) Данная стратегия направлена на обеспечение равномерного покрытия всей длины генома. Для каждого гена вычисляется его средняя позиция на основе координат начала и конца:

$$\text{pos}_g = \frac{\text{start}_g + \text{end}_g}{2}.$$

Затем с учётом смещений между хромосомами рассчитывается глобальная позиция:

$$\text{global_pos}_g = \text{offset}(c) + \text{pos}_g,$$

где $\text{offset}(c)$ — суммарная длина всех предыдущих хромосом. Гены сортируются по глобальной позиции, и отбираются N генов с равномерным шагом:

$$\text{selected}_k = \text{sorted_genes} \left[\left\lfloor \frac{k \cdot M}{N} \right\rfloor \right], \quad k = 0, 1, \dots, N - 1,$$

где M — общее количество генов.

Равномерный отбор внутри хромосом (uniform per chromosome selection)

Наиболее совершенная стратегия, сочетающая пропорциональное распределение генов по хромосомам с равномерным отбором внутри каждой хромосомы. Целевое количество генов для c -й хромосомы определяется пропорционально её физической длине:

$$N_c = \max \left(1, \left\lfloor N \cdot \frac{L_c}{L_{\text{total}}} \right\rfloor \right),$$

где L_c — длина c -й хромосомы, L_{total} — суммарная длина всех хромосом. Внутри каждой хромосомы гены сортируются по позиции и отбираются с равномерным шагом, что обеспечивает равномерное покрытие как по хромосомам, так и внутри них.

2.1.8 Настройки процесса обучения

Обучение модели производится с использованием оптимизатора AdamW [18], который совмещает в себе преимущества адаптивной настройки скорости обучения и регуляризации через weight decay. Начальная скорость обучения составляет 10^{-4} , коэффициент weight decay — 10^{-2} .

Для динамического уменьшения скорости обучения применяется планировщик ReduceLROnPlateau, который снижает learning rate в два раза при отсутствии улучшения валидационной ошибки в течение пяти эпох.

Функция потерь В теоретической постановке задачи (раздел 2.1) в качестве функции потерь была введена среднеквадратическая ошибка (MSE). Однако в процессе практической реализации выяснилось, что MSE чувствительна к выбросам в данных, что характерно для генетических экспериментов. Поэтому в данной работе используется HuberLoss (также известная как SmoothL1Loss) — комбинированная функция потерь, которая сочетает преимущества MSE и MAE [17]:

$$\mathcal{L}_{\delta}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| < \delta, \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2, & \text{иначе,} \end{cases}$$

где $\delta = 1.0$ — параметр, определяющий границу между квадратичной и линейной областями.

При малых ошибках ($|y - \hat{y}| < \delta$) функция ведёт себя как MSE, обеспечивая гладкую оптимизацию. При больших ошибках переходит в линейную зависимость, что делает её устойчивой к выбросам. Таким образом, HuberLoss сохраняет теоретическую обоснованность MSE, но на практике демонстрирует более стабильное обучение.

2.1.9 Механизмы регуляризации

Для предотвращения переобучения в модели используются следующие механизмы регуляризации:

- A. **Dropout**: применяется в трансформерном блоке (вероятность отключения $p = 0.2$) и в блоке предсказания ($p = 0.3$). Dropout случайно обнуляет долю нейронов на каждой итерации обучения, что снижает склонность модели к запоминанию обучающей выборки и улучшает обобщающую способность.

- B. **Weight decay** (L_2 -регуляризация): используется в оптимизаторе AdamW с коэффициентом 10^{-2} , что накладывает штраф на большие значения весов модели.
- C. **Early stopping**: обучение останавливается, если валидационная ошибка не улучшается в течение 20 эпох, что предотвращает переобучение на поздних этапах.
- D. **Реконструкционная регуляризация**: вспомогательная задача реконструкции входных SNP-маркеров с убывающим коэффициентом α_{recon} также способствует регуляризации, особенно на ранних этапах обучения.

3 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ ПРЕДСКАЗАТЕЛЬНОЙ СПОСОБНОСТИ МОДЕЛИ

В данной главе представлены результаты вычислительных экспериментов по оценке предсказательной способности разработанной модели. Исследование проводилось на трёх наборах генетических данных, соответствующих различным сельскохозяйственным культурам: нут, рис и рапс. Для каждой культуры решалась задача многомерной регрессии, в которой по SNP-маркерам требовалось предсказать количественные фенотипические признаки.

Первая часть главы посвящена сравнительному анализу базовой и модифицированной архитектур на данных нута и риса. Оценка качества производилась с использованием коэффициента корреляции Пирсона, среднеквадратичной ошибки, а также путём анализа распределений предсказанных значений. Вторая часть главы содержит результаты экспериментов на данных рапса, где была исследована эффективность различных стратегий отбора генов.

3.1 Сравнительный анализ архитектур на данных нута и риса

3.1.1 Экспериментальные условия

Для сравнительного анализа двух архитектур (базовой и модифицированной) были использованы данные нута и риса. Экспериментальные условия для каждого набора данных приведены в таблице 3.1.

Таблица 3.1

Условия проведения экспериментов

Параметр	Нут	Рис
Количество образцов	553	469
Количество SNP	5 783	1 708*
Количество генов	2 837	1 599
Среднее SNP на ген	2.04	1.07
Целевые признаки	TSW, Ptht	Plant height, Tiller number
Разделение выборок	80/10/10	80/10/10
Аугментация	MixUp ($\lambda = 0.0625$)	MixUp ($\lambda = 0.0625$)

* — после фильтрации аннотированных SNP




Рис.3.1. Динамика функции потерь при обучении модифицированной модели на данных нута

3.1.2 Результаты на данных нута

На данных нута сравнивались две архитектуры: базовая (эксперимент Е) и модифицированная, включающая механизм внимания на уровне SNP и реконструкционную регуляризацию. Динамика функции потерь в процессе обучения модифицированной модели представлена на рисунке 3.1.

Итоговые значения коэффициента корреляции Пирсона на тестовой выборке составили для модифицированной модели:

- масса тысячи семян (TSW): $r = 0.881$;
- высота растения (Ptht): $r = 0.773$.

Для базовой модели (эксперимент Е) соответствующие значения составили $r = 0.91$ для TSW и $r = 0.79$ для Ptht. Несмотря на более высокие корреляционные показатели базовой модели, её обучение характеризовалось значительной неста-




Рис.3.2. Корреляционный график для массы тысячи семян (TSW) на данных нута




Рис.3.3. Корреляционный график для высоты растения (Pht) на данных нута

бильностью на начальных эпохах, а также выраженным эффектом сглаживания предсказаний.

На рисунках 3.2 и 3.3 представлены корреляционные графики для модифицированной модели на данных нута.

Анализ распределений предсказанных значений показал, что модифицированная модель лучше сохраняет дисперсию выходных данных:

- для TSW: $Std(\hat{y}) = 67.88$ при $Std(y) = 92.40$ (сокращение дисперсии на 26.5%);
- для Pht: $Std(\hat{y}) = 5.41$ при $Std(y) = 8.70$ (сокращение дисперсии на 37.8%).

В базовой модели сокращение дисперсии для Pht составило около 40%, что подтверждает более выраженное сглаживание.

3.1.3 Результаты на данных риса

Для оценки обобщающей способности модифицированной архитектуры эксперимент был повторён на данных риса. Итоговые значения коэффициента корреляции Пирсона на тестовой выборке для модифицированной модели составили:

- высота растения (Plant height): $r = 0.830$;
- число побегов (Tiller number): $r = 0.516$.




Рис.3.4. Корреляционный график для высоты растения (Plant height) на данных риса

Таблица 3.2

Сравнение результатов базовой и модифицированной архитектур

Культура	Признак	Базовая	Модифицированная	Изменение
Нут	TSW	0.910	0.881	-3.2%
	Ptht	0.790	0.773	-2.2%
Рис	Plant height	0.847	0.830	-2.0%
	Tiller number	0.600	0.516	-14.0%

Для сравнения, базовая модель на тех же данных, обученная с аналогичными гиперпараметрами, достигла корреляции $r = 0.847$ для высоты растения и $r = 0.600$ для числа побегов. Таким образом, базовая модель показывает преимущество в корреляционных показателях на данных риса, особенно для второго признака (разрыв составил 14%).

Важно отметить, что базовая модель на данных риса была обучена на отфильтрованном наборе SNP (только аннотированные маркеры, что составило 29.5% от исходного объёма). Это привело к значительной потере генетической информации, однако модель всё равно показала высокие результаты, что свидетельствует о её способности выделять наиболее информативные маркеры даже при сильной фильтрации.

На рисунках 3.4 и 3.5 представлены корреляционные графики для модифицированной модели на данных риса.

3.1.4 Сравнительный анализ качества прогнозирования

Сводные результаты экспериментов на двух культурах представлены в таблице 3.2.




Рис.3.5. Корреляционный график для числа побегов (Tiller number) на данных риса

Таблица 3.3

Сравнение эффекта сжатия дисперсии на данных риса

Модель	Признак	Std факт	Std предск
Базовая	Plant height	26.23	20.19
	Tiller number	3.48	1.79
Модифицированная	Plant height	26.23	11.30
	Tiller number	3.48	1.53

Как видно из таблицы, базовая модель демонстрирует более высокие корреляционные показатели на обоих наборах данных. Однако эти показатели достигаются ценой нестабильности обучения и более агрессивного сглаживания предсказаний.

3.1.5 Анализ сжатия дисперсии

Сравнение эффекта сжатия дисперсии на тестовой выборке риса (таблица 3.3) выявило интересную закономерность: модифицированная модель демонстрирует более сильное сжатие дисперсии для основного признака (57% против 23% у базовой), что противоречит наблюдениям на данных нута.

Это объясняется тем, что на данных риса плотность SNP на ген крайне низка (1.07), и модифицированная модель пытается компенсировать недостаток информации за счёт регуляризации, что приводит к более сильному сжатию дисперсии. На данных нута, где плотность SNP на ген выше (2.04), модифицированная модель, напротив, лучше сохраняет индивидуальные различия между образцами.




Рис.3.6. Динамика функции потерь на обучающей и тестовой выборках в эксперименте E (базовая архитектура с оптимизированными настройками)

3.1.6 Анализ устойчивости обучения

Важным преимуществом модифицированной архитектуры является стабильность процесса обучения. На рисунке 3.1 можно наблюдать плавное и монотонное снижение функции потерь для модифицированной модели на данных нута.

Для наглядного сравнения на рисунке 3.6 представлена динамика функции потерь базовой модели (эксперимент E) в процессе обучения.

Как видно из графика, начальные этапы обучения базовой модели характеризуются значительной нестабильностью, что проявляется в резких колебаниях тестовой ошибки. Это связано с чувствительностью базовой архитектуры к инициализации параметров. После нескольких уменьшений скорости обучения процесс оптимизации стабилизируется.

Модифицированная модель, благодаря реконструкционной регуляризации, обучается более плавно и предсказуемо с самого начала, без резких колебаний.

3.1.7 Эксперименты с базовой моделью

Для получения референтной точки и оценки вклада архитектурных изменений были проведены дополнительные эксперименты с базовой архитектурой (эксперимент E). Базовая модель имеет следующую конфигурацию:

- генетическое кодирование: свёрточная агрегация SNP с обучаемыми весами;

- трансформерный блок: один слой с одной головой внимания ($d = 32$, $h = 1$, $ff = 64$);
- блок прогнозирования: полносвязная сеть с разворачиванием генных представлений в вектор.

Ключевые отличия от первоначальной реализации включают использование функции потерь SmoothL1Loss (вместо MSE), аугментации MixUp и адаптивного планировщика скорости обучения ReduceLROnPlateau.

На данных нута базовая модель достигла корреляции $r = 0.91$ для TSW и $r = 0.79$ для Ptht, что лишь незначительно превышает результаты модифицированной модели (0.881 и 0.773 соответственно). Однако базовая модель показала выраженную нестабильность на начальных этапах обучения и более сильное сглаживание предсказаний (сокращение дисперсии для Ptht около 40% против 37.8% у модифицированной).

На данных риса преимущество базовой модели в корреляционных показателях стало более заметным, особенно для второго признака (число побегов): $r = 0.600$ против 0.516 у модифицированной. Это может быть связано с тем, что при крайне низкой плотности SNP на ген (1.07) механизм внимания модифицированной модели не может эффективно использоваться из-за недостатка маркеров для обучения адаптивных весов.

3.1.8 Анализ влияния архитектурных модификаций

Сравнение результатов, полученных на данных нута и риса, выявляет различное поведение базовой и модифицированной архитектур в зависимости от характеристик данных. На нуте, характеризующемся более высокой плотностью SNP на ген (2.04 против 1.07 у риса), разрыв в корреляционных показателях между моделями оказался минимальным: модифицированная модель уступила базовой около 3% по TSW и 2% по Ptht. На рисе этот разрыв составил 2% для высоты растения и 14% для числа побегов.

Однако делать однозначный вывод о том, что наблюдаемые различия обусловлены исключительно плотностью SNP, преждевременно. На качество прогнозирования могут влиять и другие факторы: генетическая архитектура целевых признаков, размер обучающей выборки, качество аннотации генома и др.

Для более детальной проверки влияния внедрённых архитектурных модификаций (механизма внимания на уровне SNP и реконструкционной регуляризации)

Таблица 3.4

Общая характеристика генетических данных рапса

Параметр	Значение
Всего SNP	1 272 066
SNP с аннотацией гена	100%
Уникальных генов	60 768
Среднее SNP на ген	21.31
Медиана SNP на ген	16.00
Максимум SNP на ген	745

необходимо протестировать модель на данных с существенно большей плотностью SNP на ген, чем в нуте и рисе. Такой анализ представлен в следующем разделе на примере данных рапса, где среднее количество SNP на ген составляет 21.3, что на порядок превышает соответствующие показатели ранее использованных культур.

3.2 Эксперименты на данных рапса

Для более детальной проверки эффективности разработанных архитектурных модификаций, в частности механизма внимания на уровне SNP и реконструкционной регуляризации, были проведены эксперименты на данных рапса (*Brassica napus*). Данная культура была выбрана по следующим причинам:

- высокая плотность SNP на ген (в среднем 21.3 против 2.04 у нута и 1.07 у риса);
- большое количество образцов (991);
- разнообразие фенотипических признаков (время цветения, содержание масла, белка, глюкозинолатов и др.);
- полная аннотация SNP к генам (100% покрытие).

3.2.1 Характеристика данных

Генетические данные рапса содержат информацию о SNP-маркерах, их хромосомной локализации и аннотации к генам. Основные характеристики приведены в таблице 3.4.

Фенотипические данные включают широкий спектр признаков. Для данной работы наибольший интерес представляют время цветения (FloweringTime) и содержание глюкозинолатов (GlucosinolateContent), поскольку они аналогич-

Таблица 3.5

Статистика фенотипических признаков рапса

Признак	Образцов	Среднее $\pm$ std	Диапазон
FloweringTime	926	176.7 ± 10.50	125–206
GlucosinolateContent	279	116.9 ± 52.82	10.3–203.6

ны признакам, исследованным на нуте и рисе. Статистические характеристики фенотипических признаков представлены в таблице 3.5.

3.2.2 Стратегии отбора генов

При работе с большим количеством генов (60 768) возникает необходимость их фильтрации для снижения вычислительной сложности. В данной работе исследованы три стратегии отбора генов:

3.2.2.1 Взвешенный отбор (*weighted selection*)

Все гены ранжируются по убыванию количества SNP и разбиваются на четыре квартиля. Целевое распределение количества отбираемых генов задаётся весами: первый квартиль (гены с наименьшим количеством SNP) получает вес 0.1, второй — 0.2, третий — 0.3, четвёртый (гены с наибольшим количеством SNP) — 0.4.

3.2.2.2 Равномерный отбор по геному (*uniform position selection*)

Для каждого гена вычисляется глобальная позиция с учётом смещений между хромосомами. Гены сортируются по глобальной позиции, и отбираются N генов с равномерным шагом, что обеспечивает равномерное покрытие всей длины генома.

3.2.2.3 Равномерный отбор внутри хромосом (*uniform per chromosome selection*)

Целевое количество генов для каждой хромосомы определяется пропорционально её физической длине:

$$N_{\text{chr}} = \max \left(1, \left\lfloor N_{\text{total}} \cdot \frac{L_{\text{chr}}}{L_{\text{total}}} \right\rfloor \right),$$

где L_{chr} — длина хромосомы, L_{total} — суммарная длина всех хромосом. Внутри каждой хромосомы гены отбираются с равномерным шагом, что обеспечивает равномерное покрытие как по хромосомам, так и внутри них.

Таблица 3.6

Сравнение стратегий отбора генов

Стратегия	SNP	FT Corr	Gluco Corr	Эпохи
Weighted	85 208	0.798	0.793	88
Uniform position	63 035	0.850	0.776	78
Uniform per chromosome	63 005	0.850	0.783	78

Таблица 3.7

Сравнение механизмов агрегации SNP

Признак	Метрика	Conv1d	Attention	Δ
FloweringTime	Корреляция	0.8539	0.8898	+0.0359
	MAE	3.84	4.09	+0.25
	MAPE (%)	2.32%	2.41%	+0.09%
GlucosinolateContent	Корреляция	0.7488	0.7716	+0.0228
	MAE	25.19	28.19	+3.00
	MAPE (%)	35.05%	44.47%	+9.42%

3.2.3 Сравнение стратегий отбора генов

Для оценки эффективности различных стратегий отбора генов (описанных в разделе 2.1.7) была проведена серия экспериментов на данных рапса с предсказанием времени цветения (FloweringTime) и содержания глюкозинолатов (GlucosinolateContent). Результаты представлены в таблице 3.6.

Как видно из таблицы, стратегии равномерного отбора существенно превосходят взвешенную по качеству предсказания времени цветения (0.850 против 0.798), при этом требуя на 26% меньше SNP. Это подтверждает гипотезу о важности равномерного покрытия генома для полигенных признаков. Стратегия равномерного отбора внутри хромосом является наиболее биологически обоснованной и была выбрана для всех последующих экспериментов.

3.2.4 Сравнение механизмов агрегации SNP

Для проверки эффективности механизма внимания на уровне SNP был проведён эксперимент, в котором сравнивались два подхода к агрегации SNP внутри генов: усреднение с помощью свёртки (conv1d) и взвешенная агрегация с использованием multi-head attention. Результаты представлены в таблице 3.7.

Таблица 3.8

Влияние аугментации на качество модели с вниманием

Признак	Метрика	Без аугментации	С аугментацией	Δ
FloweringTime	Корреляция	0.8898	0.8896	−0.0002
	MAE	4.09	4.47	+0.38
	MAPE (%)	2.41%	2.62%	+0.21%
GlucosinolateContent	Корреляция	0.7716	0.7644	−0.0072
	MAE	28.19	24.38	−3.81
	MAPE (%)	44.47%	35.54%	−8.93%

Механизм внимания показал превосходство над свёрткой для обоих признаков: улучшение корреляции составило 3.6% для времени цветения и 2.3% для содержания глюкозинолатов. Это объясняется способностью внимания динамически взвешивать важность каждого SNP внутри гена, в то время как свёртка выполняет простое усреднение. Кроме того, модель с вниманием оказалась более параметроэффективной: 4.85 млн параметров против 6.47 млн у модели со свёрткой.

3.2.5 Влияние аугментации

Для оценки влияния аугментации на качество прогнозирования был проведён эксперимент с применением метода MixUp. Результаты представлены в таблице 3.8.

Аугментация оказала дифференцированное влияние: для времени цветения наблюдается незначительное ухудшение метрик, в то время как для содержания глюкозинолатов произошло значительное улучшение точности абсолютных значений (MAPE снизился на 8.93%, MAE — на 3.81). Это свидетельствует о том, что время цветения является более простым для прогнозирования признаком и не требует аугментации, тогда как содержание глюкозинолатов — сложный метаболический признак, где аугментация помогает обобщению.

3.2.6 Мультизадачное обучение

Для улучшения обобщающей способности модели были проведены эксперименты с одновременным предсказанием двух признаков. Использовалось пересечение образцов, для которых доступны оба признака (271 образец). Результаты представлены в таблице 3.9.

Таблица 3.9

Результаты мультизадачного обучения

Признак	Val Corr	Test Corr	MAE
FloweringTime + GlucosinolateContent			
FloweringTime	0.736	0.798	5.59 дней
GlucosinolateContent	0.842	0.793	26.79
FloweringTime + OilContent			
FloweringTime	0.758	0.809	5.27 дней
OilContent	0.508	0.240	1.85

Таблица 3.10

Влияние усложнения архитектуры на качество предсказания

Модель	Параметров	FT Corr	FT MAE	FT MAPE
Базовая (32/1/64/3)	3.19M	0.850	4.48	2.65%
Усложнённая (64/1/128/4)	6.47M	0.854	4.26	2.54%

Оба признака в паре с временем цветения предсказываются с высокой точностью (корреляция ≈ 0.8 для глюкозинолатов и 0.809 для времени цветения в паре с содержанием масла). Особенно впечатляющим является результат для глюкозинолатов — признака, который ранее не использовался в подобных задачах. Важно отметить, что время цветения в мультизадачной конфигурации с содержанием масла достигло наилучшего результата (0.809) — выше, чем при обучении на 926 образцах, что демонстрирует эффект мультизадачного обучения как регуляризатора.

3.2.7 Усложнение архитектуры

Дополнительно был проведён эксперимент с усложнённой архитектурой модели ($\text{embed_dim} = 64$, $\text{ff_dim} = 128$, $\text{num_layers} = 4$) при использовании стратегии равномерного отбора внутри хромосом. Результаты представлены в таблице 3.10.

Усложнение модели позволило достичь наилучшего результата для времени цветения: корреляция Пирсона составила 0.854 при средней абсолютной процентной ошибке 2.54%. Однако прирост качества оказался незначительным (+0.4% по корреляции) при двукратном увеличении числа параметров модели, что делает базовую конфигурацию предпочтительной для практического применения.

3.2.8 Кросс-культурный анализ

Сравнение результатов, полученных на трёх культурах, позволяет сделать следующие выводы о влиянии архитектурных модификаций:

- На нуте (2.04 SNP/ген) модифицированная модель показала результаты, сопоставимые с базовой (TSW: 0.881 против 0.910), продемонстрировав при этом более стабильное обучение и лучшее сохранение дисперсии.
- На рисе (1.07 SNP/ген) разрыв в корреляции между моделями увеличился (14% для второго признака), что указывает на ограничения модифицированной модели при крайне низкой плотности маркеров.
- На рапсе (21.3 SNP/ген) механизм внимания на уровне SNP показал своё преимущество перед свёрткой, улучшив корреляцию на 3.6% для времени цветения и на 2.3% для содержания глюкозинолатов. Это подтверждает, что предложенные модификации наиболее эффективны при высокой плотности SNP-маркеров.

3.2.9 Выводы по экспериментам на рапсе

На основе проведённых экспериментов можно сделать следующие выводы:

- A. **Равномерный отбор генов** существенно превосходит взвешенный по качеству предсказания времени цветения (0.850 против 0.798), подтверждая важность равномерного покрытия генома для полигенных признаков.
- B. **Механизм внимания на уровне SNP** превосходит свёртку для обоих признаков, особенно для времени цветения ($\Delta r = +0.0359$), и является более параметроэффективным ($\approx 25\%$ меньше параметров).
- C. **Аугментация** полезна для сложных метаболических признаков (содержание глюкозинолатов: MAPE улучшился на 8.93%), но не требуется для хорошо предсказуемых признаков (время цветения).
- D. **Мультизадачное обучение** позволяет улучшить качество предсказания основного признака даже при меньшем количестве образцов за счёт эффекта регуляризации.
- E. **Усложнение архитектуры** даёт лишь незначительное улучшение качества (0.854 против 0.850) при двукратном увеличении вычислительных затрат, что делает базовую конфигурацию предпочтительной.

Таким образом, эксперименты на рапсе подтвердили эффективность предложенных архитектурных модификаций, в особенности механизма внимания на

уровне SNP, и позволили определить оптимальные настройки для практического применения модели.

4 АНАЛИЗ МЕЖГЕННЫХ ВЗАИМОДЕЙСТВИЙ С ИСПОЛЬЗОВАНИЕМ ЗНАЧЕНИЙ ШЕПЛИ

В данной главе представлены результаты анализа межгенных взаимодействий, полученные с применением значений Шепли. Этот метод позволяет оценить вклад совместного действия пар генов в предсказание фенотипических признаков, что особенно важно для интерпретации моделей глубокого обучения в задачах геномного прогнозирования. В первой части главы приводится теоретическое обоснование метода Шепли и его адаптация для анализа генных взаимодействий. Во второй части представлены результаты вычислений на обученной модели с использованием данных риса, включая матрицу взаимодействий, гистограммы распределения значений и анализ наиболее значимых генов. В третьей части приведены результаты анализа на данных рапса, позволяющие сопоставить структуру межгенных взаимодействий для разных культур.

4.1 Теоретические основы метода Шепли

4.1.1 Значения Шепли в задачах интерпретации моделей

Значения Шепли (Shapley values) являются концепцией из теории кооперативных игр, предложенной Ллойдом Шепли в 1953 году. [25] В контексте интерпретации моделей машинного обучения этот метод позволяет справедливо распределить вклад каждого признака в предсказание модели. [19] Основная идея заключается в том, что важность признака определяется как средний вклад этого признака при добавлении его во все возможные подмножества других признаков.

Для модели машинного обучения f и набора признаков N значение Шепли для признака i вычисляется по формуле:

$$\varphi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)],$$

где S — подмножество признаков, не содержащее i , а $f(S)$ — предсказание модели при использовании только признаков из подмножества S .

4.1.2 Адаптация для анализа парных взаимодействий генов

Для оценки вклада совместного действия двух генов используется расширение значений Шепли на взаимодействия второго порядка.[11] Величина взаимодействия между генами i и j вычисляется как:

$$\varphi_{i,j} = \mathbb{E}_{S \subseteq N \setminus \{i,j\}} [f(S \cup \{i,j\}) - f(S \cup \{i\}) - f(S \cup \{j\}) + f(S)],$$

где N — множество всех генов, S — случайное подмножество генов, не содержащее i и j , а $f(\cdot)$ — предсказание модели для заданного подмножества генов.

Интерпретация полученных значений:

- $\varphi_{i,j} > 0$ — совместная активация генов приводит к усилению предсказания по сравнению с их индивидуальными эффектами (синергия);
- $\varphi_{i,j} < 0$ — совместная активация приводит к ослаблению предсказания (антагонизм);
- $\varphi_{i,j} \approx 0$ — взаимодействие между генами отсутствует или незначительно.

4.1.3 Вычислительная сложность и приближённые методы

Прямое вычисление значений Шепли требует перебора всех $2^{|N|}$ подмножеств признаков, что невозможно для геномных данных с тысячами генов. Для практической реализации используются приближённые методы, основанные на Монте-Карло-сэмплировании. В данной работе для каждой пары генов генерируется фиксированное количество случайных подмножеств S (параметр SHAPLEY_SUBSET_SIZE = 50), после чего вычисляется среднее значение $\varphi_{i,j}$ по всем подмножествам.

4.1.4 Отбор наиболее значимых генов

Для уменьшения вычислительной сложности перед вычислением значений Шепли производится отбор наиболее значимых генов. В данной работе используется метод оценки чувствительности на основе градиентов: вычисляются градиенты выхода модели по эмбедингам генов, после чего отбираются гены с наибольшей абсолютной чувствительностью. Формально, для каждого гена g вычисляется: $\text{saliency}_g = \left\| \frac{\partial \hat{y}}{\partial \mathbf{e}_g} \right\|_2$, где $\mathbf{e}_g$ — эмбединг гена g , $\hat{y}$ — предсказание модели. В данном исследовании было отобрано TOP_K = 150 генов с наибольшей чувствительностью.

4.2 Результаты анализа на данных риса

4.2.1 Экспериментальные условия

Анализ межгенных взаимодействий проводился на обученной модели PhenotypePredictionModel с использованием данных риса. Основные параметры анализа:

- Количество анализируемых генов: $K = 150$;
- Количество случайных подмножеств для каждой пары: 50;
- Целевой признак: высота растения (Plant height);
- Количество образцов для анализа: 5 (для ускорения вычислений).

4.2.2 Матрица взаимодействий генов

На рисунке 4.1 представлена тепловая карта матрицы взаимодействий генов, где цветом отображены значения Шепли для каждой пары генов.

Как видно из тепловой карты, большинство значений Шепли близки к нулю, что указывает на отсутствие сильных взаимодействий между большинством пар генов. Однако присутствуют отдельные ярко выраженные взаимодействия как положительного, так и отрицательного знака.

4.2.3 Распределение значений Шепли

На рисунке 4.2 представлена гистограмма распределения значений Шепли для всех пар анализируемых генов.

Распределение имеет ярко выраженный пик в окрестности нуля, что подтверждает, что большинство пар генов не демонстрируют значимых взаимодействий. Хвосты распределения (положительные и отрицательные значения) содержат небольшое количество пар с выраженными взаимодействиями.

4.2.4 Наиболее выраженные взаимодействия

В таблице 4.1 представлены пять наиболее сильных положительных и пять наиболее сильных отрицательных взаимодействий для данных риса.

Важно отметить, что ген Os01g0125800 участвует в четырёх из пяти положительных взаимодействий и в трёх из пяти отрицательных, что делает его ключевым




Рис.4.1. Матрица взаимодействий генов на данных риса (значения Шепли). Красный цвет соответствует положительным взаимодействиям (синергия), синий — отрицательным (антагонизм).



Рис.4.2. Распределение значений Шепли для пар генов на данных риса

Таблица 4.1

Наиболее выраженные генные взаимодействия на данных риса

Положительные взаимодействия		
Ген 1	Ген 2	Значение Шепли
Os01g0111100	Os01g0125800	0.007591
Os01g0121200	Os01g0125800	0.007388
Os01g0155500	Os01g0125800	0.007145
Os01g0110200	Os01g0125800	0.006882
Os01g0143900	Os01g0125800	0.006467
Отрицательные взаимодействия		
Ген 1	Ген 2	Значение Шепли
Os01g0125700	Os01g0125800	-0.011734
Os01g0150000	Os01g0125800	-0.008125
Os01g0108800	Os01g0150000	-0.006920
Os01g0159400	Os01g0150000	-0.006704
Os01g0159400	Os01g0125800	-0.006609

узлом в сети межгенных взаимодействий. Также ген Os01g0150000 участвует в двух отрицательных взаимодействиях.

4.2.5 Анализ центральности генов

Для количественной оценки важности каждого гена в сети взаимодействий была вычислена центральность как сумма абсолютных значений Шепли для всех пар с участием данного гена:

$$C_g = \sum_{h \neq g} |\varphi_{g,h}|.$$

В таблице 4.2 представлены десять генов с наибольшей центральностью для данных риса.

Ген Os01g0125800 обладает наибольшей центральностью (0.421), что подтверждает его роль как ключевого регулятора в сети взаимодействий. Ген Os01g0150000 с центральностью 0.373 также является важным узлом. Значения центральности для остальных генов из топ-10 находятся в диапазоне 0.246–0.294.

Таблица 4.2

ТОП-10 генов по центральности на данных риса

Ген	Центральность
Os01g0125800	0.420983
Os01g0150000	0.373452
Os01g0125500	0.293615
Os01g0113700	0.266809
Os01g0126200	0.263856
Os01g0125700	0.263188
Os01g0152700	0.260168
Os01g0126600	0.250808
Os01g0137800	0.247678
Os01g0108200	0.245985




Рис.4.3. ТОП-10 генов по сумме абсолютных значений Шепли на данных риса

4.2.6 Биологические функции ключевых генов

Для двух генов риса с наибольшей центральностью по данным NCBI установлены следующие аннотированные функции.

Ген Os01g0125800 кодирует белок «Actin-Interacting Protein 1» (AIP1), участвующий в перестройке актинового цитоскелета. В базе данных Gene Ontology для этого гена указаны процессы, связанные с регуляцией динамики актиновых филаментов.[3; 23]

Ген Os01g0150000 соответствует локусу *OsCER10* (ECERIFERUM 10) и кодирует фермент very-long-chain enoyl-CoA reductase, вовлечённый в биосинтез воска кутикулы.

4.3 Результаты анализа на данных рапса

4.3.1 Экспериментальные условия

Для сопоставительного анализа межгенных взаимодействий аналогичные вычисления были проведены на данных рапса. Основные параметры анализа:

- Целевой признак: время цветения (FloweringTime);
- Количество анализируемых генов: $K = 150$;
- Количество случайных подмножеств для каждой пары: 50;
- Количество образцов для анализа: 5.

4.3.2 Результаты анализа

Результаты вычислений значений Шепли для данных рапса представлены в таблице 4.3. Положительные значения указывают на синергетические взаимодействия между генами, отрицательные — на антагонистические.

На рисунке 4.4 представлена тепловая карта матрицы взаимодействий генов для данных рапса.

Как видно из тепловой карты, большинство значений Шепли близки к нулю, что подтверждает разреженную структуру межгенных взаимодействий. Отдельные ярко выраженные пары генов выделяются на общем фоне.

Таблица 4.3

Наиболее выраженные геновые взаимодействия на данных рапса

Положительные взаимодействия		
Ген 1	Ген 2	Значение Шепли
gene-LOC106381653	gene-LOC106382058	0.000666
gene-LOC106383181	gene-LOC111207063	0.000537
gene-LOC125584419	gene-LOC106428178	0.000477
gene-LOC106381653	gene-LOC106406961	0.000459
gene-LOC106406961	gene-LOC106381653	0.000457
Отрицательные взаимодействия		
Ген 1	Ген 2	Значение Шепли
gene-LOC106412350	gene-LOC106428178	-0.000487
gene-LOC106423494	gene-LOC106352190	-0.000475
gene-LOC111207309	gene-LOC106425166	-0.000469
gene-LOC106381653	gene-LOC106425166	-0.000469
gene-LOC106381653	gene-LOC106425166	-0.000469

4.3.3 Анализ центральности генов

Для количественной оценки важности каждого гена в сети взаимодействий была вычислена центральность как сумма абсолютных значений Шепли для всех пар с участием данного гена:

$$C_g = \sum_{h \neq g} |\varphi_{g,h}|.$$

В таблице 4.4 представлены десять генов с наибольшей центральностью для данных рапса.

Ген gene-LOC106381653 обладает наибольшей центральностью (0.0264), что указывает на его ключевую роль в сети взаимодействий. [7] Гены gene-LOC106428178 и gene-LOC106423494 также демонстрируют высокие значения центральности. По сравнению с данными риса, где максимальная центральность достигала 0.421, значения на рапсе на порядок ниже. Это может быть связано с тем, что на рапсе анализировался другой фенотипический признак (время цветения), а также с различной плотностью SNP-маркеров и геномной архитектурой культур.




Рис.4.4. Матрица взаимодействий генов на данных рапса (значения Шепли)

Таблица 4.4

ТОП-10 генов по центральности на данных рапса

Ген	Центральность
gene-LOC106381653	0.026449
gene-LOC106428178	0.024266
gene-LOC106423494	0.023018
gene-LOC106382058	0.022516
gene-LOC111207063	0.022130
gene-BNAA03G58270D	0.021960
gene-BNAA07G05990D	0.021439
gene-LOC106398224	0.020650
gene-LOC106425166	0.020058
gene-LOC106352190	0.019975




Рис.4.5. ТОП-10 генов по сумме абсолютных значений Шепли на данных рапса

Таблица 4.5

Сравнение ключевых генов-«хабов» на разных культурах

Параметр	Рис	Рапс
Количество анализируемых генов	150	150
Наибольшая центральность	0.421 (Os01g0125800)	0.026 (gene-LOC106381653)
Диапазон значений Шепли	[-0.0117, 0.0076]	[-0.00049, 0.00067]
Характер взаимодействий	Выраженные кластеры	Разреженная структура

4.3.4 Аннотация ключевого гена рапса

Ген gene-LOC106381653, обладающий наибольшей центральностью, согласно базе данных NCBI имеет следующую официальную аннотацию. Тип гена — белок-кодирующий. Описание: «UPF0725 protein At5g63820-like». Ген расположен на хромосоме C3, содержит 6 экзонов. В консервативных доменах белка присутствует домен неизвестной функции DUF626 (pfam04776). По данным OrthoDB, для этого гена найдены ортологи у других растений. Статус RefSeq — MODEL.

4.3.5 Сравнительный анализ

Сравнение результатов, полученных на данных риса и рапса, позволяет сделать следующие наблюдения (таблица 4.5):

Полученные результаты демонстрируют, что структура межгенных взаимодействий существенно различается для разных культур и целевых признаков. Для времени цветения рапса выявлена более разреженная сеть взаимодействий с меньшими абсолютными значениями Шепли по сравнению с высотой растения риса. Это может указывать на разную генетическую архитектуру этих признаков: время цветения, вероятно, контролируется большим количеством генов с малыми эффектами, тогда как высота растения риса может определяться меньшим числом генов с более выраженными эффектами и взаимодействиями.

Важно отметить, что ген *gene-LOC106381653*, обладающий наибольшей центральностью на рапсе, участвует как в положительных (с генами *gene-LOC106382058* и *gene-LOC106406961*), так и в отрицательных (с генами *gene-LOC106425166*) взаимодействиях, что делает его ключевым узлом в сети регуляции времени цветения. Аналогичная роль отмечена для гена *gene-LOC106428178*, участвующего в положительном взаимодействии с геном *gene-LOC125584419* и отрицательном — с геном *gene-LOC106412350*.

4.4 Выводы по главе

В данной главе был применён метод Шепли для анализа межгенных взаимодействий в обученной модели прогнозирования фенотипов на данных риса и рапса. Были получены следующие результаты:

- A. Разработан программный модуль для вычисления значений Шепли с использованием Монте-Карло-сэмплирования, позволяющий оценивать парные взаимодействия генов.
- B. Построена матрица взаимодействий для 150 наиболее значимых генов, выявлена разреженная структура взаимодействий.
- C. На данных риса обнаружены гены-«хабы» — *Os01g0125800* и *Os01g0150000* (индексы 145 и 271), участвующие в наибольшем количестве взаимодействий с другими генами. Центральность *Os01g0125800* составила 0.421, что более чем в 1.5 раза превышает центральность следующего по значимости гена.
- D. На данных рапса ключевым геном-«хабом» является *gene-LOC106381653* (индекс 269) с центральностью 0.0264. Этот ген участвует как в положительных (с генами *106382058* и *106406961*), так и в отрицательных (с

геном 106425166) взаимодействиях, что делает его важным регуляторным узлом в сети контроля времени цветения.

- Е. Выявлены синергетические пары генов, совместная активация которых усиливает предсказание фенотипа (например, пары Os01g0111100 — Os01g0125800 на рисе и LOC106381653 — LOC106382058 на рапсе), а также антагонистические пары, где происходит взаимное подавление (Os01g0125700 — Os01g0125800 на рисе и LOC106412350 — LOC106428178 на рапсе).
- Ф. Проведён сопоставительный анализ с данными рапса, который выявил существенные различия в структуре межгенных взаимодействий: для времени цветения рапса характерна более разреженная сеть с меньшими абсолютными значениями Шепли по сравнению с высотой растения риса.
- Г. Полученные результаты могут быть использованы для планирования дальнейших биологических экспериментов по валидации выявленных генных взаимодействий, в частности для генов-«хабов» Os01g0125800 (рис) и gene-LOC106381653 (рапс), которые представляют наибольший интерес как потенциальные мишени для селекции.

ЗАКЛЮЧЕНИЕ

В данной выпускной квалификационной работе была разработана, программно реализована и протестирована модель глубокого обучения для прогнозирования фенотипических признаков сельскохозяйственных растений по генотипическим данным, представленным в виде однонуклеотидных полиморфизмов (SNP). Исследование проводилось на трёх культурах: нут (*Cicer arietinum*), рис (*Oryza sativa*) и рапс (*Brassica napus*), что позволило оценить обобщающую способность предложенной архитектуры.

Основные результаты работы

- A. **Разработана архитектура модели**, включающая четыре основных блока: генетического кодирования с механизмом внимания на уровне SNP, трансформерный блок для моделирования межгенных взаимодействий, блок прогнозирования фенотипов и реконструкционный блок для регуляризации скрытых представлений. Предложенная архитектура позволяет адаптивно взвешивать вклад отдельных SNP-маркеров при формировании генных представлений и учитывать сложные нелинейные зависимости между генами.
- B. **Реализован программный комплекс** на базе библиотеки PyTorch, включающий модули для загрузки и предобработки генетических данных, частотного кодирования SNP, аугментации методом MixUp, обучения модели с многозадачной функцией потерь и адаптивным взвешиванием признаков, а также для анализа межгенных взаимодействий с использованием значений Шепли.
- C. **Проведена серия вычислительных экспериментов** на данных трёх культур. Наибольшая точность прогнозирования достигнута для времени цветения рапса (коэффициент корреляции Пирсона 0.809) и массы тысячи семян нута (0.881). Для данных риса получены корреляции 0.830 для высоты растения и 0.516 для числа побегов.
- D. **Исследованы методы аугментации данных**. Сравнительный анализ показал, что метод MixUp эффективнее аугментации перестановкой хромосом, особенно для сложных метаболических признаков (содержа-

ние глюкозинолатов: MAPE улучшился на 8.93%), при этом для хорошо предсказуемых признаков (время цветения) аугментация не требуется.

- Е. **Сравнены стратегии отбора генов** для работы с высокоразмерными геномными данными. Равномерный отбор по геному и равномерный отбор внутри хромосом существенно превосходят взвешенный отбор по качеству предсказания времени цветения (0.850 против 0.798), при этом требуя на 26% меньше SNP.
- Ф. **Выполнена интерпретация модели** с помощью значений Шепли. На данных риса выявлены гены-«хабы» Os01g0125800 и Os01g0150000, участвующие в наибольшем количестве взаимодействий. На данных рапса ключевым геном-«хабом» является gene-LOC106381653. Структура выявленных взаимодействий (наличие генов с множеством как положительных, так и отрицательных связей) соответствует паттерну ключевых регуляторных генов.

Научная новизна и практическая значимость

Научная новизна работы заключается в предложении архитектуры модели с механизмом внимания на уровне SNP и реконструкционной регуляризацией, а также в разработке многозадачной функции потерь с адаптивным взвешиванием фенотипических признаков.

Практическая значимость состоит в создании программной реализации модели, которая может быть использована в селекционных программах для идентификации генетических маркеров [10; 21], связанных с продуктивностью, устойчивостью к засухе и другими хозяйственно ценными признаками. Полученные результаты подтверждают применимость подхода в регионах рискованного земледелия для ускоренного выведения адаптированных сортов.

Перспективы дальнейших исследований

Дальнейшее развитие работы может включать следующие направления:

- А. Тестирование модели на других сельскохозяйственных культурах (пшеница, ячмень, соя) для подтверждения обобщающей способности.
- В. Экспериментальная валидация выявленных генов-«хабов» (Os01g0125800 у риса и gene-LOC106381653 у рапса) с использованием методов обратной генетики или анализа экспрессии.

- С. Разработка веб-сервиса для онлайн-прогнозирования фенотипов по SNP-данным, доступного для селекционеров и исследователей.

Итоговый вывод

Разработанная модель глубокого обучения на основе трансформерной архитектуры с механизмом внимания на уровне SNP и реконструкционной регуляризацией успешно справляется с задачей прогнозирования фенотипических признаков сельскохозяйственных культур. Эффективность подхода подтверждена на данных трёх культур, различающихся по плотности SNP-маркеров и геномной архитектуре. Возможность интерпретации модели с помощью значений Шепли позволяет выявлять значимые межгенные взаимодействия и гены-кандидаты, что делает разработанный инструмент ценным не только для прогнозирования, но и для понимания молекулярных механизмов формирования агрономически важных признаков.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. A transformer-based genomic prediction method fused with knowledge-guided module / C. Wu [и др.] // *Briefings in Bioinformatics*. — 2023. — Т. 25, № 1. — bbad438. — DOI 10.1093/bib/bbad438.
2. Attention is All You Need / A. Vaswani, N. Shazeer, N. Parmar [и др.] // *Advances in Neural Information Processing Systems*. — 2017. — Т. 30. — С. 5998—6008. — URL: <https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf>.
3. Cicer super-pangenome provides insights into species evolution and agronomic trait loci for crop improvement in chickpea / A. W. Khan [и др.] // *Nature Genetics*. — 2024. — Т. 56. — С. 1225—1234. — DOI 10.1038/s41588-024-01760-4.
4. CropGS-Hub: a comprehensive database of genotype and phenotype resources for genomic prediction in major crops / J. Chen, C. Tan, M. Zhu [и др.] // *Nucleic Acids Research*. — 2024. — Т. 52, № D1. — С. D1519—D1529. — DOI 10.1093/nar/gkad1062.
5. Data Augmentation Enhances Plant-Genomic-Enabled Predictions / O. A. Montesinos-López [и др.] // *Genes*. — 2024. — Т. 15, № 3. — С. 286. — DOI 10.3390/genes15030286.
6. Dropout: A Simple Way to Prevent Neural Networks from Overfitting / N. Srivastava, G. Hinton, A. Krizhevsky [и др.] // *Journal of Machine Learning Research*. — 2014. — Т. 15. — С. 1929—1958. — URL: <https://jmlr.org/papers/v15/srivastava14a.html>.
7. Ecology and genomics of an important crop wild relative as a prelude to agricultural innovation / E. von Wettberg [и др.] // *Nature Communications*. — 2018. — Т. 9. — С. 649. — DOI 10.1038/s41467-018-02867-z.
8. *Endelman J. B.* Ridge Regression and Other Kernels for Genomic Selection with R Package rrBLUP // *The Plant Genome*. — 2011. — Т. 4, № 3. — DOI 10.3835/plantgenome2011.08.0024.
9. Evaluating dimensionality reduction for genomic prediction / V. Manthana [и др.] // *Frontiers in Genetics*. — 2022. — Т. 13. — С. 958780. — DOI 10.3389/fgene.2022.958780.
10. Exploring genetic variation for salinity tolerance in chickpea using image-based phenotyping / J. Atieno [и др.] // *Scientific Reports*. — 2017. — Т. 7. — С. 1300. — DOI 10.1038/s41598-017-01211-7.

11. Gene-gene interaction detection with deep learning / T. Cui, K. El Mekkaoui, J. Reinval [и др.] // *Communications Biology*. — 2022. — Т. 5. — С. 1238. — DOI 10.1038/s42003-022-04186-y.
12. Genetic variation and association mapping for 12 agronomic traits in indica rice / Q. Lu, M. Zhang, X. Niu [и др.] // *BMC Genomics*. — 2015. — Т. 16. — С. 1067. — DOI 10.1186/s12864-015-2245-2.
13. Genomic Selection in Plant Breeding: Methods, Models, and Perspectives / J. Crossa [и др.] // *Trends in Plant Science*. — 2017. — Т. 22, № 11. — С. 961—975. — DOI 10.1016/j.tplants.2017.08.011.
14. Genomic Selection: A Tool for Accelerating the Efficiency of Molecular Breeding for Development of Climate-Resilient Crops / N. Budhlakoti [и др.] // *Frontiers in Genetics*. — 2022. — Т. 13. — С. 832153. — DOI 10.3389/fgene.2022.832153.
15. GPTransformer: A Transformer-Based Deep Learning Method for Predicting Fusarium Related Traits in Barley / S. Jubair [и др.] // *Frontiers in Plant Science*. — 2021. — Т. 12. — С. 761402. — DOI 10.3389/fpls.2021.761402.
16. GSCNN: A genomic selection convolutional neural network model based on SNP genotype and physical distance features and data augmentation strategy / L. Ji, W. Hou, L. Xiong [и др.]. — 2024. — DOI 10.21203/rs.3.rs-3991262/v1. — (Preprint at Research Square).
17. *Huber P. J.* Robust Estimation of a Location Parameter // *The Annals of Mathematical Statistics*. — 1964. — Т. 35, № 1. — С. 73—101. — URL: <https://projecteuclid.org/euclid.aoms/1177703732>.
18. *Loshchilov I., Hutter F.* Decoupled Weight Decay Regularization // *International Conference on Learning Representations (ICLR)*. — 2019. — URL: <https://arxiv.org/abs/1711.05101>.
19. *Lundberg S. M., Lee S.-I.* A Unified Approach to Interpreting Model Predictions // *Advances in Neural Information Processing Systems*. — 2017. — Т. 30. — С. 4765—4774. — URL: <https://proceedings.neurips.cc/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf>.
20. *Meuwissen T., Hayes B., Goddard M.* Genomic Selection: A Paradigm Shift in Animal Breeding // *Animal Frontiers*. — 2016. — Т. 6, № 1. — С. 6—14. — DOI 10.2527/af.2016-0002.
21. Modeling Chickpea Productivity with Artificial Image Objects and Convolutional Neural Network / M. Bankin [и др.] // *Plants*. — 2024. — Т. 13, № 17. — DOI 10.3390/plants13172444.

22. *Pérez P., Campos G. d. l.* Genome-Wide Regression and Prediction with the BGLR Statistical Package // *Genetics*. — 2014. — Т. 198, № 2. — С. 483—495. — DOI 10.1534/genetics.114.164442.
23. Resequencing of 429 chickpea accessions from 45 countries provides insights into genome diversity, domestication and agronomic traits / R. K. Varshney [и др.] // *Nature Genetics*. — 2019. — Т. 51, № 6. — С. 857—864. — DOI 10.1038/s41588-019-0401-3.
24. *Reutov A. A., Chibyshev T. A., Kozlov K. N.* Сравнительный анализ методов аугментации данных в задачах геномного прогнозирования // *Научно-технические ведомости СПбГПУ*. — 2025. — (в печати).
25. *Shapley L. S.* A Value for n-person Games. — 1953.
26. To Transformers and Beyond: Large Language Models for the Genome / M. E. Consens [и др.] // *arXiv*. — 2023. — Т. abs/2311.07621. — DOI 10.48550/arxiv.2311.07621.
27. Whole-genome resequencing of a worldwide collection of rapeseed accessions reveals the genetic basis of ecotype divergence / D. Wu, Z. Liang, T. Yan [и др.] // *Molecular Plant*. — 2019. — Т. 12. — С. 30—43. — DOI 10.1016/j.molp.2018.11.005.
28. *Domanov O.* BibLATEX support for GOST standard bibliographies. — URL: <https://ctan.org/pkg/biblatex-gost> (visited on 06.03.2019).